



T.C.  
**İSTANBUL RUMELİ ÜNİVERSİTESİ**  
**MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ**  
**END 401 UYGULAMA PROJESİ**

**PERAKENDE KARAR DESTEK SİSTEMİ ARAYÜZ  
SİMÜLASYONU**

**İbrahim TÜRKYILMAZ**

**İSTANBUL**

**2026**



T.C.  
**İSTANBUL RUMELİ ÜNİVERSİTESİ**  
**MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ**  
**ENDÜSTRİ MÜHENDİSLİĞİ BÖLÜMÜ**

**END 402 UYGULAMA PROJESİ**

**PERAKENDE KARAR DESTEK SİSTEMİ ARAYÜZ  
SİMÜLASYONU**

**İbrahim TÜRKYILMAZ**

**Proje Danışmanı  
Dr. Öğr. Üyesi Ayla ÖZTÜRK**

**İSTANBUL**

**2026**

## **ETİK BEYANI**

Endüstri Mühendisliği Bölümü END401 Uygulama Projesi olarak sunduğum “Perakende Karar Destek Sistemi Arayüz Simülasyonu” adlı çalışmanın, tarafimdan bilimsel ahlak ve geleneklere aykırı düşecek bir yardıma başvurmaksızın yazıldığını ve yararlandığım eserlerin kaynakçada gösterilen eserlerden olduğunu, bunlara atıf yapılarak yararlanmış olduğumu belirtir ve bunu onurumla doğrularım.

İbrahim TÜRKYILMAZ

İMZA

## **TEŞEKKÜR**

Bu çalışmanın gerçekleştirilmesinde, çalışmam boyunca benden bir an olsun yardımlarını esirgemeyen saygıdeğer danışman hocam Dr. Öğr. Üyesi Ayla ÖZTÜRK, hayatımın her evresinde bana destek olan değerli aileme sonsuz teşekkürlerimi sunarım.

İbrahim TÜRKYILMAZ

İstanbul, Ocak 2025

## ÖZET

### PERAKENDE KARAR DESTEK SİSTEMİ ARAYÜZ SİMÜLASYONU

İbrahim TÜRKYILMAZ

Mühendislik ve Doğa Bilimleri Fakültesi

Endüstri Mühendisliği Bölümü

Uygulama Projesi

Danışman: Dr. Öğr. Üyesi Ayla ÖZTÜRK

Günümüz perakende sektöründe artan rekabet ve veri yoğunluğu, yöneticilerin hızlı ve doğru karar almasını zorlaştırmaktadır. Özellikle talep belirsizliği ve mağazalar arası stok dengesizliği, sezgisel yaklaşımalarla etkin biçimde yönetilememektedir. Bu çalışmanın amacı; talep tahmini ve mağazalar arası ürün transferi (Lateral Transshipment) kararlarını destekleyen matematiksel modelleri, bütünsel bir Karar Destek Sistemi (KDS) içerisinde sunmaktadır.

Geliştirilen sistem, karmaşık analitik ve optimizasyon modellerini kullanıcılar için anlaşılır içgörülere dönüştürerek “Hangi ürün, hangi mağazaya transfer edilmelidir?” sorusuna veriye dayalı yanıtlar üretmektedir. Çalışma, özellikle KOBİ ölçüngindeki perakendeciler için yüksek maliyetli ERP çözümlerine alternatif, çevik ve ölçeklenebilir bir yapı sunması açısından önem taşımaktadır. Sistem, modern web teknolojileri ile geliştirilmiş ve Açıklanabilir Yapay Zeka (XAI) prensipleriyle desteklenmiştir.

Metodoloji kapsamında; merkezi depo, mağazalar ve ara depodan oluşan bir lojistik ağ yapısı simüle edilmiş, gerçekçi senaryoları yansıtacak şekilde sentetik veri üretilmiştir. Talep tahminlemesinde istatistiksel yöntemler, stok dengeleme problemlerinde ise Ağgözlü Sezgisel (Greedy Heuristic) yaklaşım kullanılmıştır.

Elde edilen sonuçlar, geliştirilen web tabanlı karar destek arayüzünün mağazalar arası ürün transferlerini daha dengeli hale getirdiğini, yok satma riskini azalttığını ve yöneticilere proaktif karar alma hızı kazandırdığını göstermektedir.

**Anahtar Sözcükler:** Karar Destek Sistemleri, Stok Optimizasyonu, Talep Tahminleme, Lateral Transshipment, Açıklanabilir Yapay Zeka

## ABSTRACT

### RETAIL DECISION SUPPORT SYSTEM INTERFACE SIMULATION

İbrahim TÜRKYILMAZ

Istanbul Rumeli University

Faculty of Engineering and Natural Sciences

Senior Project in Industrial Engineering

Advisor: Asst. Prof. Ayla ÖZTÜRK

In today's retail sector, increasing competition and data density make it difficult for managers to make fast and accurate decisions. In particular, demand uncertainty and inter-store stock imbalance cannot be managed effectively with intuitive approaches. The aim of this study is to present mathematical models supporting demand forecasting and lateral transshipment decisions within an integrated Decision Support System (DSS).

The developed system transforms complex analytical and optimization models into understandable insights for users, generating data-driven answers to the question "Which product should be transferred to which store?". The study is significant as it offers an agile and scalable structure as an alternative to high-cost ERP solutions, especially for SME-scale retailers. The system is developed with modern web technologies and supported by Explainable Artificial Intelligence (XAI) principles.

Within the scope of the methodology, a logistics network structure consisting of a central warehouse, stores, and an intermediate warehouse (hub) was simulated, and synthetic data was generated to reflect realistic scenarios. Statistical methods were used in demand forecasting, and a Greedy Heuristic approach was used in stock balancing problems.

The obtained results show that the developed web-based decision support interface makes inter-store product transfers more balanced, reduces the risk of stock-outs, and provides managers with proactive decision-making speed.

**Keywords:** Decision Support Systems, Inventory Optimization, Demand Forecasting, Lateral Transshipment, Explainable AI

## **İÇİNDEKİLER**

	<b>Sayfa No</b>
<b>ETİK BEYANI</b>	<b>3</b>
<b>TEŞEKKÜR</b>	<b>4</b>
<b>ÖZET</b>	<b>5</b>
<b>ABSTRACT</b>	<b>5</b>
<b>TABLOLAR DİZİNİ</b>	<b>8</b>
<b>ŞEKİLLER DİZİNİ</b>	<b>9</b>
<b>KISALTMALAR</b>	<b>10</b>
<b>1. GİRİŞ</b>	<b>1</b>
<b>1. LİTERATÜR TARAMASI</b>	<b>4</b>
<b>2. METODOLOJİ</b>	<b>25</b>
<b>KAYNAKLAR</b>	<b>34</b>
<b>ÖZGEÇMİŞ</b>	<b>37</b>

## **TABLOLAR DİZİNİ**

	<b>Sayfa No</b>
Tablo 1. Merkezi Dağıtım Modeli ve Hub-and-Spoke Modeli Karşılaştırması	17
Tablo 2: Transfer Politikaları Karşılaştırması	19
Tablo 3. Projede Kullanılan Teknik Mimari ve Araçlar	27
Tablo 4. Karar Destek Sistemi Modül ve Algoritmalar	29

## **ŞEKİLLER DİZİNİ**

	<b>Sayfa No</b>
Şekil 1. Kapsam ve Topoloji Kısıtları Şeması	26
Şekil 2. Talep Tahminleme ve Soğuk Başlangıç Şeması	28
Şekil 3. Heuristic (Sezgisel) Algoritma Şeması (Robin Hood Mantığı)	31

## KISALTMALAR

Bu çalışmada kullanılmış kısaltmalar, açıklamaları ile birlikte aşağıda sunulmuştur.

<b>Kısaltma</b>	<b>Açıklama</b>
<b>ACID</b>	Atomicity, Consistency, Isolation, Durability (Veritabanı İşlem Bütünlüğü)
<b>AD</b>	Ara Depo
<b>AI</b>	Artificial Intelligence (Yapay Zeka)
<b>ANN</b>	Artificial Neural Networks (Yapay Sinir Ağları)
<b>API</b>	Application Programming Interface (Uygulama Programlama Arayüzü)
<b>ARIMA</b>	Auto-Regressive Integrated Moving Average
<b>AWS</b>	Amazon Web Services
<b>BI</b>	Business Intelligence (İş Zekası)
<b>CASE</b>	Computer-Aided Software Engineering (Bilgisayar Destekli Yazılım Müh.)
<b>CDC</b>	Central Distribution Center (Merkezi Dağıtım Merkezi)
<b>DDDM</b>	Data-Driven Decision-Making (Veri Odaklı Karar Verme)
<b>DDPFF</b>	Dynamic Dual-Phase Forecasting Framework
<b>DL</b>	Deep Learning (Derin Öğrenme)
<b>DSS</b>	Decision Support Systems (Karar Destek Sistemleri)
<b>EOQ</b>	Economic Order Quantity (Ekonomik Sipariş Miktarı)
<b>ERP</b>	Enterprise Resource Planning (Kurumsal Kaynak Planlama)
<b>KDS</b>	Karar Destek Sistemi
<b>k-NN</b>	k-Nearest Neighbors (k-En Yakın Komşu Algoritması)
<b>KOBİ</b>	Küçük ve Orta Büyüklükteki İşletmeler
<b>KPI</b>	Key Performance Indicator (Anahtar Performans Göstergesi)
<b>LIME</b>	Local Interpretable Model-Agnostic Explanations
<b>LSTM</b>	Long Short-Term Memory (Uzun Kısa Süreli Bellek)
<b>LTL</b>	Less Than Truckload (Parsiyel Taşıma)
<b>MD</b>	Merkezi Depo
<b>MINLP</b>	Mixed Integer Non-Linear Programming
<b>ML</b>	Machine Learning (Makine Öğrenmesi)
<b>RDS</b>	Relational Database Service (İlişkisel Veritabanı Hizmeti)
<b>SARIMA</b>	Seasonal Auto-Regressive Integrated Moving Average
<b>SHAP</b>	SHapley Additive exPlanations
<b>SKU</b>	Stock Keeping Unit (Stok Tutma Birimi)
<b>SMDP</b>	Semi-Markov Decision Processes (Yarı-Markov Karar Süreçleri)
<b>SMOTE</b>	Synthetic Minority Over-sampling Technique
<b>XAI</b>	Explainable AI (Açıklanabilir Yapay Zeka)

# 1. GİRİŞ

Günümüz perakende sektöründe, artan rekabet koşulları ve değişen tüketici alışkanlıklarını, veriye dayalı karar alma süreçlerini bir zorunluluk haline getirmiştir. Geleneksel perakendecilikte, stok yönetimi genellikle mağaza yöneticilerinin tecrübelerine veya geçmiş satışların basit bir analize tabi tutulmasına dayanmaktadır. Ancak bu yaklaşım, özellikle çok şubeli yapılarda "stoksuz kalma" (stock-out) nedeniyle ciro kaybına veya "aşırı stok" (over-stock) nedeniyle sermayenin verimsiz kullanılmasına yol açmaktadır.

Bu çalışmanın temel amacı; perakende zincirleri için satış verilerini analiz eden, gelecek dönem taleplerini tahminleyen ve mağazalar arası ürün transferlerini optimize eden bütünlük bir Karar Destek Sistemi (KDS) geliştirmektir. Proje, sadece veriyi raporlayan pasif bir sistem değil, yöneticilere "Hangi mağazadan hangi mağazaya ürün transfer edilmeli?" sorusunun cevabını veren proaktif bir araç sunmayı hedeflemektedir.

## 1.1. Çalışmanın Önemi ve Okuyucuya Katkısı

Bu proje raporu, modern web teknolojilerinin (Python/FastAPI ve React.js) endüstri mühendisliği problemleriyle (Stok Optimizasyonu, Talep Tahmini) nasıl entegre edilebileceğine dair uygulamalı bir örnek sunmaktadır. Okuyucular, bu çalışmayı inceleyerek aşağıdaki konularda bilgi sahibi olacaklardır:

Ham satış verilerinin işlenerek anlamlı iş zekası (BI) içgörülerine dönüştürülmesi süreçleri.

Mağazalar arası yatay transfer (Lateral Transshipment) stratejisinin lojistik maliyetlere etkisi.

"What-If" (Senaryo) analizleri ile fiyat değişimlerinin ciro üzerindeki olası etkilerinin simülasyonu.

Bu çalışma, özellikle KOBİ ölçüdeki perakendeciler için yüksek maliyetli kurumsal yazılımlara (ERP) alternatif, çevik ve ölçeklenebilir bir çözüm mimarisi önermesi açısından önem taşımaktadır.

## **1.2. Araştırma Soruları ve Hipotez**

Bu çalışma kapsamında aşağıdaki temel araştırma sorularına cevap aranmaktadır:

Soru 1: Mağazalararası ürün transferi (Lateral Transshipment), merkezi depo-mağaza ikmal stratejisine kıyasla yok satma oranını ve toplam stok maliyetlerini azaltabilir mi?

Soru 2: Merkezi depoya ek olarak kullanılan bir ara depo (hub) yapısı, mağazalararası ve depo-mağaza transfer süreçlerinde hız ve çevikliği artırırken, toplam lojistik ve stok maliyetleri üzerinde artırıcı bir etki mi yaratır yoksa maliyetleri düşürücü bir rol mü üstlenir?

Soru 3: “Ara depo sadece lokal bir çözüm mü olmalı, yoksa belirli koşullarda merkezi deponun yükünü hafifleten bölgesel bir hub olarak tüm sistemde değer yaratabilir mi?”

Bu sorular doğrultusunda çalışmanın temel hipotezi şu şekilde belirlenmiştir: Geliştirilen karar destek sistemi, yöneticilerin sezgisel kararlarına kıyasla yok satma oranı, stok devir hızı ve toplam stok maliyetleri açısından daha tutarlı ve daha verimli stok dengeleme kararları alınmasını sağlar.

## **1.3. Çalışmanın Kısıtları**

Projenin kapsamı ve eldeki kaynaklar doğrultusunda bazı kısıtlar bulunmaktadır:

**Veri Seti:** Çalışmada kullanılan veriler, gerçek ticari sırlar içerdiginden dolayı, gerçek hayat senaryolarına sadık kalınarak “faker” ve “numpy” kütüphaneleri ile sentetik olarak üretilmiştir.

**Sistem Yapısı:** Bu çalışmada ele alınan lojistik ağ yapısı; bir adet merkezi depo, beş adet perakende mağazası ve mağaza 3 ile mağaza 5 arasında konumlandırılmış bir ara depodan oluşmaktadır. Merkezi depo, tüm mağazalara doğrudan sevkıyat yapabilmektedir. Ara depo, öncelikli olarak mağaza 3 ve mağaza 5 için ara ikmal noktası olarak görev yapmakta olup, gerekli senaryolarda diğer mağazalara da destekleyici ikmal sağlayabilmektedir. Bu yapı ile ara depo kullanımının, sistemin tepki süresi, çevikliği ve merkezi depo üzerindeki operasyonel yük ile toplam lojistik maliyetler üzerindeki etkileri analiz edilmektedir.

1 adet Merkezi Depo (MD)

5 adet Mağaza (M1, M2, M3, M4, M5)

1 adet Ara Depo (AD): Mağaza 3 ile Mağaza 5 arasında konumlandırılmıştır

Merkezi depo, tüm mağazalara doğrudan sevkiyat yapabilir. Merkezi depo, ara depoya ürün sevkiyatı yapabilir. Ara depo, Öncelikli olarak Mağaza 3 ve Mağaza 5'i besler. Gerekli görülen senaryolarda diğer mağazalara (M1, M2, M4) destekleyici ikmal noktası olarak hizmet verebilir.

Çoklu depo veya uluslararası lojistik süreçleri kapsam dışıdır.

Tahmin Modeli: Derin öğrenme (LSTM vb.) yerine, kural tabanlı istatistiksel tahmin yöntemleri ve "what-if" simülasyonları tercih edilmiştir.

Bu çalışma, belirtilen kısıtlar altında, veri odaklı bir perakende yönetim panelinin prototipini ortaya koymaktadır.

#### **1.4. Projenin Niteliği ve Gelecek Potansiyeli**

Bu proje bir simülasyon ve demo çalışması olarak tasarlanmıştır. Geliştirilen modüler Backend API mimarisi ve veritabanı yapısı, akademik ve ticari anlamda daha kapsamlı gelecek çalışmalar için sağlam bir altyapı niteliği taşımaktadır.

Mevcut haliyle web tabanlı çalışan bu prototip, sahip olduğu esnek mimari sayesinde üzerinde yapılacak ek geliştirmelerle kolaylıkla Masaüstü uygulamasına (Desktop App), Saha çalışanları için Mobil Uygulamaya (Mobile App) dönüştürülebilir. Dolayısıyla bu çalışma, sadece bir bitirme projesi değil, aynı zamanda ölçeklenebilir bir yazılım ekosisteminin temeli olarak değerlendirilmelidir.

## **1. LİTERATÜR TARAMASI**

Bu bölümde, literatür taramasını derinleştirmek amacıyla konular sınıflandırılarak ele alınmıştır. Modern perakende operasyonlarında verimliliği artırmak amacıyla kullanılan veri tabanlı karar destek sistemleri, stok yönetimi stratejileri ve lojistik ağ yapıları kapsamlı bir şekilde incelenmektedir. Özellikle talep tahminlemede geleneksel istatistiksel yöntemlerden derin öğrenme ve yapay zeka modellerine geçişin stratejik önemini vurgularken, geçmiş verisi olmayan yeni ürünler için "soğuk başlangıç" sorununa çözümler sunmaktadır. Merkezi dağıtım ile hub-and-spoke modellerinin operasyonel avantajları karşılaştırılmakta ve statik ağların esnekliğini artıran mağazalararası transfer (LTR) yönteminin maliyetleri düşürmedeki rolü analiz edilmektedir. Ayrıca, sentetik veri kullanımının getirdiği riskler ile insan-makine etkileşiminin karar kalitesi üzerindeki etkileri de ele alınmaktadır. Sonuç olarak literatür taraması bölümü, başarılı bir perakende yönetimi için hassas talep tahminlerinin, optimize edilmiş lojistik ağlarla ve dinamik envanter paylaşım sistemleriyle entegre edilmesi gerektiğini savunmaktadır.

### **1.1 Veri Tabanlı Karar Destek Sistemleri (Decision Support Systems – DSS)**

Modern perakende ve tedarik zinciri yönetiminde Karar Destek Sistemleri (DSS), verinin stratejik bir varlığa dönüşümünü sağlayan temel bir teknoloji olarak evrilmiştir. Başlangıçta yapılandırılmış problemlere odaklanan bu sistemler, günümüzde karmaşık ve dinamik pazar koşullarında operasyonel verimliliği artırmaktan stratejik rekabet avantajı sağlamaya kadar geniş bir yelpazede kritik bir rol oynamaktadır. Veri odaklı karar alma süreci, envanterin optimize edilmesinden müşteri taleplerinin öngörülmesine kadar tüm değer zincirini kapsayan kararlar için sağlam bir zemin oluşturarak, perakende işletmelerinin daha çevik, bilinçli ve kârlı hareket etmelerini mümkün kılmaktadır.

### **1.2 Karar Destek Sistemlerinin Tanımı ve Gelişimi**

Karar Destek Sistemleri (DSS), yöneticilerin ve bilgi çalışanlarının karmaşık problemleri analiz etmelerine, alternatifleri değerlendirmelerine ve daha etkili kararlar vermelerine yardımcı olan interaktif, bilgisayar tabanlı sistemler olarak tanımlanır. Bu sistemlerin teorik temelleri ve popülerliği, 1970'lerde Warfield tarafından yapılan çalışmalarla önemli ölçüde artmıştır. Warfield'in sistem yapısını anlama üzerine odaklanan çalışmaları, DSS'in inşası için gerekli olan yapısal modelleme yaklaşımlarına öncülük

etmiştir (Warfield, 1974). Zaman içinde, teknolojideki gelişmelerle birlikte DSS de evrilmiştir. İlk dönemlerde daha çok modele dayalı olan bu sistemler, veri ambarları ve iş zekası araçlarının yaygınlaşmasıyla veri odaklı bir karaktere bürünmüştür. Son yıllarda, DSS tasarımcılarının ve analistlerin ihtiyaçları doğrultusunda, sistem yapısını anlamaya yönelik yapılandırılmış tekniklere olan ilgi yeniden canlanmıştır. Bu canlanma, özel amaçlı dillerin geliştirilmesi ve bilgisayar destekli yazılım mühendisliği (CASE) araçlarının entegrasyonu gibi modern yaklaşımları da beraberinde getirmiştir (Warfield, 1974).

### **1.3 Veri Tabanlı Karar Alma Yaklaşımı**

Veri ambarları (Data Warehouse), organizasyonların farklı operasyonel sistemlerinden (örneğin, satış, finans, müşteri ilişkileri) gelen verileri tek bir merkezi depoda birleştirerek veri odaklı karar alma sürecinin temelini oluşturur. Bu merkezileştirme, kullanıcılar için şeffaf bir veri ortamı yaratır ve veri madenciliği, raporlama ve analistik sorgular gibi süreçlerin verimli bir şekilde yürütülmesini sağlar. Veri odaklı karar verme (Data-Driven Decision-Making - DDDM), bu altyapı üzerinde yükselserek organizasyonlar için somut faydalar üretir. Panda Retail Company üzerinde yapılan bir alan çalışması, entegre bilgi sistemlerinin (ERP) sağladığı verilerin, mobil envanter yönetimi gibi uygulamalar aracılığıyla karar süreçlerini nasıl doğrudan desteklediğini göstermektedir. Karar Destek Sistemleri ve veri ambarları, kurumsal kaynak planlama (ERP) gibi operasyonel sistemlerden toplanan zengin veriyi, son kullanıcıların sorgulama, raporlama ve analiz ihtiyaçlarına uygun bir şekilde biçimlendirerek sunar (Abdullah, 2012). Bu tür sistemler, karar vericilere gerekli bilgileri sağlayarak problem analizi ve çözüm geliştirme süreçlerini iyileştirir ve böylece DDDM'nin organizasyonel faydalarını ortaya koyar (Al-dmour vd., 2016).

### **1.4 Operasyonel ve Stratejik Kararlarda DSS Kullanımı**

Karar Destek Sistemleri, bir organizasyonun hem operasyonel hem de stratejik seviyelerindeki karar süreçlerini destekleme kapasitesine sahiptir. Bu yetenek, kurumsal katmanlar arasında farklı şekillerde kendini gösterir. Operasyonel düzeyde DSS, verimliliği en üst düzeye çıkarmak amacıyla envanter yönetimi ve sipariş karşılama gibi günlük, iyi yapılandırılmış faaliyetleri optimize etmeye odaklanır. Buna karşılık, problemlerin daha az yapılandırılmış ve daha karmaşık olduğu stratejik düzeyde, Kurumsal Kaynak Planlama (ERP) sistemleriyle entegre çalışan DSS'ler kritik bir rol oynar. ERP sistemleri, tedarik, üretim, satış ve finans gibi farklı departmanlardan gelen verileri bir araya getirerek

senkronize bir planlama ortamı sunar (Al Maruf, 2022; Wang vd., 2007). Bu entegre yapı, üst düzey yöneticilere, pazar trendlerinin analizi, uzun vadeli kapasite planlaması ve finansal tahminleme gibi organizasyonun geleceğini şekillendiren kararları, kurum genelindeki verileri kullanarak daha bütüncül ve bilinçli bir şekilde alma imkanı tanır.

### **1.5 Perakende Sektöründe Karar Destek Sistemleri**

Perakende sektörü; değişken talep döngüleri, çok sayıda satış kanalı, geniş ürün yelpazesi ve dinamik tedarik zincirleri ile karakterize edilen, doğası gereği son derece veri yoğun bir alandır. Bu karmaşıklık, Karar Destek Sistemlerinin kullanımını neredeyse bir zorunluluk haline getirmektedir. Özellikle hızlı moda gibi ürün yaşam döngülerinin kısa ve talep belirsizliğinin yüksek olduğu dinamik sektörlerde KDS, işletmelere pazar taleplerine hızlı yanıt verme ve operasyonel çeviklik kazanma konularında önemli avantajlar sağlamaktadır (Wong ve Guo, 2010). Entegre ERP-DSS platformları, perakende firmalarına operasyonel ve stratejik kararlarını güçlendiren bir dizi analitik yetenek sunar (Al Maruf, 2022). Bu platformlar, mağaza, bölge veya ürün bazında satış verilerinin anlık olarak izlenmesini sağlayan gerçek zamanlı satış performansı görselleştirmeleri sunar. Ayrıca, stok devir hızları ve yok satma oranları gibi metrikleri takip eden envanter optimizasyonu panoları ile envanterin doğru yönetilmesine yardımcı olur. Müşteri satın alma davranışlarını analiz ederek hedefli pazarlama kampanyalarını destekleyen müşteri segmentasyonu analitiği de bu yetenekler arasındadır. Ancak bu sistemlerin etkinliği, büyük ölçüde temelini oluşturan talep tahminleme modellerinin doğruluğuna bağlıdır ki bu konu Bölüm 3'te detaylı olarak ele alınacaktır.

### **1.6 DSS, BI Sistemleri ve Yönetici Bilgi Ekranları Arasındaki İlişki**

DSS, İş Zekası (Business Intelligence - BI) sistemleri ve veri ambarları, birbirile yakından ilişkili ve birbirini tamamlayan kavramlardır. Veri ambarları, farklı kaynaklardan gelen verileri depolayarak BI çözümleri için temel altyapıyı oluşturur. Bu sistemler arasındaki temel ayırım, odaklandıkları zamansal perspektif ve sordukları sorularda yatar. BI sistemleri temel olarak geriye dönük (retrospective); "ne oldu?" ve "neden oldu?" gibi sorulara yanıt arayarak geçmiş verilerin analizi yoluyla mevcut durumu anlamlandırmaya odaklanır. Buna karşılık, Karar Destek Sistemleri (DSS) ise temelde ileriye dönük (prospective); BI tarafından üretilen içgörülerini kullanarak gelecekteki senaryoları modellemek ve değerlendirmek suretiyle "ne olurdu?" ve "en iyi eylem planı nedir?" gibi soruları yanıtlar. Modern veri mimarilerinde, Hadoop gibi platformlar üzerinde

kurulan veri gölleri (data lakes), bu ilişkiyi daha da esnek hale getirmiştir. Veri gölleri, yapılandırılmış veya yapılandırılmamış her türlü veriyi ham formatında saklayarak hem veri ambarları için bir kaynak oluşturmakta hem de BI ve analistik araçları için bağımsız bir platform olarak hizmet vermektedir (Watson, 2017). Bu sistemlerin ürettiği rafine edilmiş bilgiler, nihayetinde yönetici bilgi ekranları (dashboards) aracılığıyla karar vericilere sunularak karmaşık verilerin kolayca anlaşılır ve eyleme geçirilebilir içgörülere dönüştürülmesini sağlar. DSS tarafından sağlanan bu teorik çerçeve, perakende sektöründeki stok yönetimi gibi somut ve karmaşık operasyonel problemlerin analitik yöntemlerle çözülmesi için gerekli olan zemini oluşturmaktadır. Yönetici bilgi ekranları, hem KDS hem de BI sistemlerinden elde edilen kritik performans göstergelerini (KPI) ve analiz sonuçlarını, karar vericilere özetlenmiş, anlaşılır ve eyleme geçirilebilir bir formatta sunan arayüzlerdir (Akter ve Kudapa, 2024). Dolayısıyla, yönetici bilgi ekranları bu analitik sistemlerin çıktılarının son kullanıcıya ulaştığı bir köprü görevi görür ve bu sistemlerin etkinliği, doğrudan perakende sektörünün en temel sorunlarından olan stok yönetimi problemlerinin çözümüne bağlıdır.

## **2.1 Perakende Sektöründe Stok Yönetimi Problemleri**

Perakende sektöründe stok yönetimi, yalnızca bir maliyet unsuru olmanın ötesinde, müşteri memnuniyeti, marka imajı ve finansal sürdürülebilirlik gibi alanlarda doğrudan etkisi olan stratejik bir kaldırıcıtır. Etkili bir stok yönetimi, bir yanda müşteri talebini anında karşılama hedefiyle ürün bulunurlüğunu maksimize etme, diğer yanda ise atıl sermaye ve operasyonel giderleri minimize etme arasında hassas bir denge kurmayı gerektirir. Bu nedenle, yok satma (stock-out) ve aşırı stok (overstock) gibi birbiriyile çelişen ikilemlerin başarılı bir şekilde yönetilmesi, perakendecilerin uzun vadeli başarısı için hayatı öneme sahiptir.

## **2.2 Stok Yönetiminin Stratejik Önemi**

Stok yönetimi, bir perakende işletmesinin müşteri talebini istenen hizmet seviyesinde karşılama yeteneği ile finansal olarak sürdürülebilir kalma hedefi arasındaki dengeyi sağlamada merkezi bir rol oynar. Analitik araçlarla desteklenen modern envanter yönetim sistemleri, bu dengeyi kurmada kritik bir avantaj sunar. Bu sistemler, satış işlemleri, müşteri tercihleri ve pazar trendleri gibi çeşitli veri kaynaklarını kullanarak stok seviyelerini dinamik olarak düzenler (Bock & O'Connor, 2018). Bu proaktif yaklaşım, hem stok maliyetlerini düşürür hem de ürün bulunurlığını artırarak tedarik zinciri genelinde

verimliliği önemli ölçüde iyileştirir (Goh & Lim, 2018).

### **2.3 Yok Satma (Stock-out) Problemi**

Yok satma durumu, bir ürünün rafta bulunmaması nedeniyle ortaya çıkan ve perakendeciler için çok boyutlu olumsuz sonuçlar doğuran bir problemdir. Bu durumun en bariz ve anlık etkisi, potansiyel bir satışın kaybedilmesidir. Bu etkilerin başında doğrudan satış kaybı gelirken, daha uzun vadede müşteri memnuniyetsizliği, marka sadakatının azalması ve müşterinin rakip markalara yönelmesi gibi daha ciddi sonuçlar ortaya çıkabilmektedir (Ogbo ve Onekanma, 2014). Sürekli olarak stok dışı ürünlerle karşılaşan müşteriler, markayı güvenilmez olarak algılayabileceğinden marka imajı zedelenebilir. Ayrıca, yok satma, gerçek müşteri talebinin ne olduğunu anlaşılmasını zorlaştırarak gelecekteki talep tahminlerinin doğruluğunu düşürür. Bu problem, özellikle talep belirsizliğinin yüksek olduğu ve ürün yaşam döngülerinin çok kısa olduğu hızlı moda (fast fashion) gibi sektörlerde daha da kritik hale gelmektedir.

### **2.4 Aşırı Stok (Overstock) ve Sermaye Bağlanması**

Aşırı stok tutmak, perakendeciler için ciddi finansal yükler getiren bir başka önemli problemdir. Bu maliyetler genellikle iki ana kategoriye ayrılır: depolama alanı kirası, sigorta ve elleçleme gibi doğrudan maliyetler ile daha az belirgin olmasına rağmen finansal etkisi büyük olabilen dolaylı maliyetler. Dolaylı maliyetler arasında, stoktaki ürünlerle bağlanan sermayenin atıl kalması (fırsat maliyeti), ürünlerin zamanla eskimesi veya modasının geçmesi nedeniyle değer kaybetmesi ve satılamayan ürünler elden çıkarmak için yapılan indirimlerin (markdown) kâr marjlarını eritmeye yer alır.

### **2.5 Hizmet Seviyesi ve Maliyet Dengesi**

Stok yönetiminin temel ikilemi, yüksek hizmet seviyesi (müşteri talebi karşılandığında ürün bulunurluğu oranı) ile stok tutma maliyetlerini minimize etme hedefleri arasındaki dengeyi kurmaktadır. %100 hizmet seviyesini hedeflemek, aşırı yüksek güvenlik stokları gerektirecek ve katlanılamaz maliyetlere yol açacaktır. Perakendeciler bu dengeyi optimize etmek için Ekonomik Sipariş Miktarı (EOQ) ve yeniden sipariş noktası (re-order point) gibi modern envanter kontrol tekniklerinden faydalanan (Kootanaee ve ark., 2013; Aljazzar ve ark., 2018). Bu teknikler, sipariş verme maliyetleri ile stok tutma maliyetleri arasında matematiksel bir denge kurarak toplam maliyeti en aza indiren sipariş

politikalarını belirlemeyi amaçlar. Tersine, maliyetleri en aza indirmek için stokları minimumda tutmak ise sık sık yok satma durumlarına ve müşteri kaybına neden olacaktır. Bu denge, her bir Stok Tutma Birimi (Stock Keeping Unit - SKU) için farklılık gösterebilir. Örneğin, yüksek kâr marjlı bir ürün için daha yüksek hizmet seviyesi hedeflenirken, düşük devir hızlı bir ürün için daha düşük bir hizmet seviyesi kabul edilebilir. Bu nedenle, ürünleri hacim veya değer gibi kriterlere göre sınıflandıran SKU sınıflandırma teknikleri, bu dengeyi stratejik olarak yönetmek için kritik bir öneme sahiptir (van der Walt vd., 2022).

## **2.6 Perakende Stok Problemlerinin Karar Destek Sistemleri ile İlişkisi**

Modern KDS'ler, talep tahminlerini, mevcut envanter seviyelerini, tedarik sürelerini ve hizmet seviyesi hedeflerini bir araya getirerek analitik modeller çalıştırır. Bu sistemlerin yenileme modülleri, her bir ürün ve lokasyon için optimal sipariş miktarlarını ve zamanlamasını önererek, hizmet seviyesi ile maliyet arasındaki hassas dengeyi kurmaya yardımcı olur (Van der Walt ve ark., 2022). Bu karmaşık optimizasyon sürecinin başarısı ise, tüm envanter kararlarının temelini oluşturan doğru ve güvenilir talep tahminlerinin kalitesine doğrudan bağlıdır. Stok yönetimi problemlerinin çok boyutlu ve karmaşık doğası, bu alanda Karar Destek Sistemlerinin (DSS) kullanımı için güçlü bir gerekçe oluşturmaktadır. DSS, talep belirsizliği, tedarik süresi değişkenliği ve maliyet optimizasyonu gibi faktörleri bir arada değerlendirerek perakendecilerin daha bilinçli envanter kararlarımasına yardımcı olur. Modern envanter kontrol tekniklerini kullanan bir DSS, gelecekteki satışları öngören talep tahminleri, sipariş ve stok tutma maliyetlerini dengeleyen optimum sipariş miktarları (EOQ), envanterin sipariş verilmesi gereken seviyesini tanımlayan yeniden sipariş noktaları ve beklenmedik talep dalgalarlarına karşı tampon oluşturan güvenlik stoğu seviyeleri gibi kritik parametreleri belirleyerek yok satma ve aşırı stok risklerini dengeler. Yapılan çalışmalar, Ekonomik Sipariş Miktarı (EOQ) ve yeniden sipariş noktası gibi tekniklerin sistematik olarak uygulanmasının, perakende mağazalarının tedarik zinciri performansını pozitif yönde etkilediğini göstermektedir (Wycliffe & Robert, 2025). Bu DSS güdümlü envanter kontrol tekniklerinin etkinliği, temel bir girdiye kritik derecede bağlıdır: müşteri talebinin doğru bir şekilde tahmin edilmesi. Bu nedenle, bir sonraki bölümde talep tahminleme metodolojilerinin kapsamlı bir incelemesi sunulmaktadır.

### **3.1 Talep Tahminleme Yöntemleri – Perakende Perspektifi**

Perakende sektöründe doğru talep tahminlemesi, stok optimizasyonundan fiyatlandırma stratejilerine, personel planlamasından pazarlama kampanyalarına kadar tüm tedarik zinciri ve operasyonel kararların temel taşıdır. Bu alandaki yöntemler, geçmiş verilerdeki kalıpları analiz eden geleneksel istatistiksel yaklaşımlardan, çok sayıda dışsal faktörü ve karmaşık doğrusal olmayan ilişkileri modelleyebilen modern yapay zeka yaklaşımılarına doğru önemli bir evrim geçirmiştir. Bu evrim, perakendecilere daha önce görülmemiş bir tahmin doğruluğu potansiyeli sunarken, aynı zamanda model karmaşıklığı, veri ihtiyacı ve yorumlanabilirlik gibi yeni zorlukları da beraberinde getirmiştir.

### **3.2 Geleneksel ve İstatistiksel Talep Tahminleme Yöntemleri**

İstatistiksel yöntemler, özellikle veri setlerinin daha küçük ve yönetilebilir olduğu durumlarda, yorumlanabilirliği yüksek ve uygulaması nispeten kolay çözümler sunar. Bu yöntemler, genellikle zaman serisi verisindeki trend, mevsimsellik ve döngüsellik gibi temel bileşenleri modellemeye dayanır. Ancak, temel varsayımları ve dışsal değişkenleri hesaba katmadaki kısıtlılıkları, modern perakendenin karmaşıklığı karşısında yetersiz kalmalarına neden olabilir.

#### **3.2.1 Hareketli Ortalama ve Üstel Düzeltme**

Hareketli ortalama ve üstel düzeltme (exponential smoothing) gibi zaman serisi modelleri, basitlikleri ve etkinlikleri nedeniyle özellikle kısa vadeli talep tahminlemesinde yaygın olarak kullanılmaktadır (Williams & Waller, 2010). Üstel düzeltme, geçmiş gözlemlere üssel olarak azalan ağırlıklar atayarak en son veriye daha fazla önem verir. Bu yöntemin Holt-Winters gibi gelişmiş varyasyonları, hem trend hem de mevsimsellik içeren talep desenlerini modellemede oldukça etkilidir. Gardner'in (2006) kapsamlı derlemesi, bu modellerin perakende gibi alanlarda nasıl başarılı bir şekilde uygulanabileceğini ortaya koymaktadır.

#### **3.2.2 ARIMA ve SARIMA Modelleri**

Otoregresif Bütünleşik Hareketli Ortalama (ARIMA) ve onun mevsimsel varyasyonu olan SARIMA modelleri, bir zaman serisinin geçmiş değerleri ile geçmiş tahmin hataları arasındaki otokorelasyon yapısını modelleyerek daha karmaşık talep yapılarını yakalayabilir. Bu modeller, serideki durağan olmayan trendleri farklılaştırma (differencing)

yoluyla ele alır ve bu sayede daha istikrarlı tahminler üretebilir. Özellikle e-ticaret moda perakendeciliği gibi dinamik alanlarda talep tahmininde kullanılan bu modeller, LSTM gibi daha yeni derin öğrenme yöntemleriyle karşılaşmalıdır olarak değerlendirilmektedir (Reddypogu & Prasad, 2025).

### **3.2.3 Prophet ve Klasik Zaman Serisi Yaklaşımları**

Facebook tarafından geliştirilen Prophet modeli, klasik zaman serisi ayırtırma metodlarına dayanan modern ve kullanıcı dostu bir yaklaşımdır. Prophet, bir zaman serisini trend, haftalık ve yıllık mevsimsellik ile tatil etkileri gibi bileşenlere ayırır. Özellikle güçlü mevsimsel döngülere ve düzensiz tatil etkilerine sahip perakende satış verileri için tasarlanmıştır. SARIMA ve Holt-Winters gibi klasik modellerin aksine Prophet, analistin alan bilgisine dayalı olarak modele kolayca harici değişkenler eklemesine olanak tanır ve parametre ayarlarını büyük ölçüde otomatikleştirir (Gürbüz, 2024). Bu esnekliği, onu özellikle analitik derinliği olmayan kullanıcılar için erişilebilir kılarken, geleneksel yöntemlerin aksine daha karmaşık ve çok değişkenli ilişkileri modelleyebilen makine öğrenmesi yaklaşımları için bir geçiş noktası oluşturur. Modelin en büyük avantajlarından biri, analistlerin kendi alan bilgilerini kolayca ayarlanabilen parametreler aracılığıyla modele dahil edebilmeleri, bu sayede esnek ve hızlı tahminler üretebilmeleridir (Subramanian vd., 2024).

## **3.3 Makine Öğrenmesi ve Derin Öğrenme Yaklaşımları**

Makine öğrenmesi (ML) ve derin öğrenme (DL) modelleri, geleneksel istatistiksel yöntemlerin ötesine geçerek, çok sayıda dışsal değişkeni (fiyat, promosyonlar, rakip fiyatları, hava durumu vb.) aynı anda hesaba katma yeteneği sunar. Bu modeller, verideki karmaşık, doğrusal olmayan ve örtük ilişkileri otomatik olarak öğrenerek, özellikle modern perakendenin dinamik ortamında daha yüksek tahmin doğruluğu potansiyeli vaat etmektedir (Boone vd., 2019).

### **3.3.1 Regresyon ve Ağaç Tabanlı Modeller**

Rastgele Orman (Random Forest) ve XGBoost (Extreme Gradient Boosting) gibi ağaç tabanlı topluluk modelleri, hem regresyon (talep miktarı tahmini) hem de sınıflandırma görevlerinde gösterdikleri yüksek performans nedeniyle perakende talep tahminlemesinde oldukça popülerdir. Bu modeller, çok sayıda karar ağacının tahminlerini birleştirerek çalışır ve bu sayede tek bir ağacın aşırı öğrenme eğilimini azaltır. Ayrıca,

hangi özelliklerin tahminde ne kadar önemli olduğunu belirleme ve bu özellikler arasındaki karmaşık etkileşimleri yakalama yetenekleri, onları oldukça etkili kılmaktadır (Cutler vd., 2011; Zhang vd., 2023).

### **3.3.2 Yapay Sinir Ağları ve LSTM**

Yapay Sinir Ağları (Artificial Neural Networks - ANN) ve özellikle bir tür tekrarlayan sinir ağları olan Uzun Kısa Süreli Bellek (Long Short-Term Memory - LSTM) ağları, zaman serisi verilerindeki uzun vadeli bağımlılıkları yakalamadaki üstünlükleriyle öne çıkar. Geleneksel tekrarlayan sinir ağlarının aksine LSTM, "hafıza hücreleri" sayesinde bilgiyi uzun zaman adımları boyunca saklayabilir ve bu sayede geçmişteki önemli olayların mevcut talebe etkisini modelleyebilir (Al-Taleb vd., 2022). Bu özellik, LSTM'yi özellikle mevsimsellik ve trend gibi uzun vadeli kalıpları içeren talep desenlerini öğrenmede oldukça güçlü kılar (Zhang vd., 2023).

### **3.3.3 Model Karmaşıklığı, Veri İhtiyacı ve Açıklanabilirlik Sorunu**

Derin öğrenme modellerinin sunduğu yüksek tahmin doğruluğu, bazı önemli zorlukları da beraberinde getirir. Bu modeller, karmaşık yapıları nedeniyle genellikle büyük miktarda veriye ihtiyaç duyar ve eğitilmeleri hesaplama açısından maliyetli olabilir. Ancak en önemli sorunlardan biri, "kara kutu" (black box) doğalarıdır. Bu opaklık, genellikle "kara kutu problemi" olarak adlandırılır (Adadi & Berrada, 2018) ve AI modellerinin iç öğrenme ve karar verme süreçlerinin anlaşılmasını engellediği için benimsenmesinin önünde önemli bir engel teşkil eder (Meske & Bunde, 2022). Bu açıklanabilirlik eksikliği, yöneticilerin bu karmaşık modellere olan güvenini sarsabilir ve modelin önerilerinin pratikte benimsenmesini kısıtlayabilir.

## **3.4 Sentetik Veri Kullanımı ve Genellenebilirlik Problemi**

Model performansını artırmak, özellikle de yetersiz veya dengesiz veri setleri gibi yaygın sorunların üstesinden gelmek için sentetik veri kullanımı giderek daha fazla ilgi çeken bir yaklaşımdır. Ancak bu yaklaşım, modelin genellenebilirliği ve gerçek dünya senaryolarını temsil etme yeteneği konusunda önemli zorluklar ve riskler de barındırmaktadır.

### **3.4.1 Sentetik Veri Kavramı**

Sentetik veri, gerçek verinin istatistiksel özelliklerini koruyarak, bu özelliklere dayalı

bir model aracılığıyla yapay olarak üretilen veridir (Rankin vd., 2020). Sınıflandırma problemlerinde, SMOTE (Synthetic Minority Over-sampling Technique) gibi teknikler, azınlık sınıfına ait örnekleri sentetik olarak çoğaltarak dengesiz veri setlerini iyileştirmek için yaygın olarak kullanılır. Bu, modelin nadir görülen ancak önemli olayları öğrenmesine yardımcı olur (Chawla vd., 2002).

### **3.4.2 Overfitting ve Model Drift Problemleri**

Makine öğrenmesi modellerinin karşılaştığı en temel sorunlardan biri, modelin eğitim verisine aşırı uyum sağlamasıdır (overfitting). Diğer bir önemli problem ise "model drift" veya "kavram kayması"dır. Pazar koşulları ve tüketici davranışları zamanla değişir; bu da modelin eğitildiği verinin artık mevcut gerçekliği temsil etmemesine ve tahmin doğruluğunun zamanla düşmesine yol açar. Bu fenomen, Bölüm 1'de vurgulandığı gibi, Karar Destek Sistemlerinin statik araçlar yerine dinamik ve adaptif sistemler olması gerekliliğinin altını çizer. Yapılan bir analiz, düzenli olarak yeniden eğitilmeyen perakende tahmin modellerinin performansının 18 aylık bir periyotta %14 ile %19 arasında düştüğünü göstermektedir (Antonov, 2023).

### **3.4.3 Sentetik Veri ile Gerçek Dünya Senaryolarının Temsili**

Sentetik verinin en büyük zorluğu, gerçek dünyadaki karmaşıklığı ne ölçüde doğru temsil edebildiğiidir. Örneğin, SynSys gibi sentetik veri üretim sistemleri, sağlık gibi hassas alanlarda kullanılmaktadır (Dahmen & Cook, 2019). Ancak, üretilen verinin gerçek popülasyonun tüm çeşitliliğini yansıtıp yansımadığı her zaman bir soru işaretidir. Perakende gibi dinamik bir alanda, yeni bir rakibin piyasaya girmesi gibi olayların sentetik veri ile modellenmesi oldukça zordur. Bu nedenle, sentetik veri ile eğitilen modellerin performansı dikkatle değerlendirilmelidir. Bu gelişmiş yöntemler mevcut veri akışlarını yönetmede umut vaat etse de, temelde geçmiş bilgilere dayanmaktadır. Bu durum, perakende operasyonları için kritik bir soruyu gündeme getirmektedir: Hiçbir geçmiş verinin bulunmadığı yeni bir ürün veya yeni bir mağaza için talep nasıl tahmin edilebilir? Bu zorluk "soğuk başlangıç" problemi olarak bilinir.

## **4.1 Soğuk Başlangıç Problemi (Cold Start) ve Çözüm Yaklaşımları**

Perakende sektöründe yeni bir ürün piyasaya sürüldüğünde veya yeni bir mağaza açıldığında ortaya çıkan "soğuk başlangıç" problemi, talep tahminlemesi alanındaki en zorlu konulardan biridir. Geçmiş satış verisinin olmaması, geleneksel zaman serisi

analizine dayalı yöntemleri işlevsiz kılar. Bu durum, perakendecileri ilk stok seviyelerini belirlerken önemli bir belirsizlikle karşı karşıya bırakır. Dolayısıyla, bu problemin üstesinden gelmek, ürün yaşam döngüsünün kritik olan ilk aşamalarındaki başarı için hayatı öneme sahiptir.

#### **4.2 Yeni Ürün ve Yeni Mağaza Problemleri**

Soğuk başlangıç problemi, temel olarak geçmiş talep verisi bulunmayan yeni ürünler ve yeni mağazalar için güvenilir talep tahminleri yapma zorluğu olarak tanımlanır. Bu durum, yalnızca istatistiksel zaman serisi modellerini değil, aynı zamanda geçmiş satışları bir özellik olarak kullanan birçok makine öğrenmesi modelini de etkisiz hale getirir. Bu nedenle, perakendeciler bu boşluğu doldurmak için alternatif tahmin yaklaşımılarına ihtiyaç duyarlar.

#### **4.3 Benzerlik Tabanlı Yaklaşımlar**

Soğuk başlangıç problemine yönelik en yaygın ve sezgisel çözüm, yeni ürünü veya mağazayı, özellikleri (attributeleri) bakımından benzer olan mevcut ürün veya mağazalarla eşleştirmektir. Bu yaklaşım, "benzer ürünlerin benzer talep desenlerine sahip olacağı" varsayıma dayanır. Bu benzerliği kurmak için ürün veya mağazaya ait kategori, fiyat ve lokasyon gibi metaveriler kullanılır (Smyl vd., 2018). Bu metaveriler kullanılarak yeni öğe için bir "benzerlik skoru" hesaplanır ve en benzer mevcut öğelerin talep geçmişi, yeni öğrenin talebini tahmin etmek için bir vekil (proxy) olarak kullanılır.

#### **4.4 Kümeleme (Clustering) ve k-NN Tabanlı Çözümler**

Benzerlik tabanlı yaklaşımları daha sistematik hale getirmek için denetimsiz makine öğrenmesi algoritmalarından yararlanılabilir. k-means gibi kümeleme algoritmaları, mevcut ürün veya mağazaları metaveri özelliklerine göre gruplamak için kullanılabilir (MacQueen, 1967). Yeni bir ürün, atandığı kümeyi ortalamaya talep davranışıyla tahmin edilebilir. k-En Yakın Komşu (k-NN) yaklaşımı ise, yeni bir öğrenin talebini, ona özellik uzayında en yakın olan  $k$  adet komşusunun taleplerinin ağırlıklı bir ortalaması olarak tahmin eder. k-NN, basitliği nedeniyle genellikle soğuk başlangıç senaryolarında güçlü bir temel (baseline) model olarak kullanılır (Smyl vd., 2018).

#### **4.5 Referans Sınıf Tahminleme Yaklaşımı**

Daha gelişmiş yaklaşımlar, benzerlik tabanlı tahminlemeyi zamanla gelen gerçek

verilerle adaptif bir şekilde öğrenmeyi birleştiren çerçeveler sunar. Örneğin, Dinamik Çift Fazlı Tahmin Çerçeveesi (DDPFF) bu mantıkla çalışır (Chen vd., 2025). Bu tür bir sistem, yeni ürünü öncelikle özelliklerine göre mevcut ürün kümelerinden birine atayarak bir başlangıç tahmini oluşturur. Ürün satılmaya başlandıktan ve gerçek veriler toplandıktan sonra, model bu başlangıçtaki tahmini dinamik olarak günceller. Bu yaklaşım, benzerlik tabanlı tahmin ile adaptif öğrenmeyi birleştirerek soğuk başlangıç probleminin ürünün yaşam döngüsü boyunca evrilen dinamik bir süreç olarak ele alınmasını sağlar. Talebin, zorlu soğuk başlangıç senaryolarında dahi doğru bir şekilde tahmin edilmesi, stok planlamasının ilk ve en kritik adımıdır. Ancak bu tahminin değeri, ancak ürünlerin müşteriye verimli bir şekilde ulaştırılmasıyla realize edilebilir. Bu da odağı, talebin öngörülmesinden dağıtımın fiziksel altyapısına, yani lojistik ağ yapılarına kaydırmaktadır.

### **5.1 Lojistik Ağ Yapıları ve Dağıtım Stratejileri**

Bir perakende işletmesinin lojistik ağ yapısı, ürünlerin tedarikçiden son tüketiciye ulaşana kadar izlediği fiziksel yolu tanımlar ve bu yapı, şirketin maliyet verimliliği, hizmet hızı ve pazar talebine yanıt verme esnekliği üzerinde belirleyici bir etkiye sahiptir. Doğru tasarlanmış bir dağıtım ağı, envanter maliyetlerini düşürürken müşteri memnuniyetini artırabilirken, yanlış bir yapı ise operasyonel verimsizliklere ve pazar payı kaybına yol açabilir. Bu nedenle, farklı dağıtım modellerinin stratejik avantaj ve dezavantajlarını karşılaştırmak, perakendeciler için kritik bir karar alanıdır.

### **5.2 Merkezi Depo Tabanlı Dağıtım Modeli**

Bu model, envanterin tamamının veya büyük bir kısmının tek bir veya birkaç stratejik konumdaki merkezi dağıtım merkezinde (Central Distribution Center - CDC) tutulduğu ve tüm dağıtım operasyonlarının bu merkezden yönetildiği bir yapıdır.

#### **5.2.1 Modelin Tanımı ve İşleyişi**

Merkezi dağıtım modelinde, tedarikçilerden gelen ürünler öncelikle merkezi depoya sevk edilir. Hızlı moda devi Zara'nın stratejisi bu modele iyi bir örnektir. Menşeî veya nihai hedefi ne olursa olsun, tüm ürünler ilk olarak İspanya'daki merkezi dağıtım merkezlerine gelir. Burada hızla tasnif edilip paketlenir ve ardından şirketin küresel mağaza ağına dağıtilır (Orcao & Pérez, 2014; Chu, 2005).

### **5.2.2 Avantaj ve Dezavantajların Analizi**

Merkezi modelin başlıca avantajları arasında, tüm stok tek bir yerde toplandığı için daha kolay envanter kontrolü ve görünürlüğü; farklı bölgelerin talebindeki belirsizliklerin birleşmesiyle daha az güvenlik stoğu gerektiren stok havuzlama (stock pooling) etkisi; ve tek bir büyük tesiste operasyonları birleştirerek elde edilen ölçek ekonomileri yer alır. Dezavantajları ise merkeze uzak pazarlara daha uzun teslimat süreleri, artan son mil (last-mile) taşıma maliyetleri ve merkezi depoda yaşanacak bir aksaklılığın tüm ağı felç edebileceği tek noktaya bağımlılık riskidir.

### **5.2.3 Uygulama Örnekleri**

Bir perakende firması, merkezi dağıtım modelini geleneksel bir depolama anlayışıyla değil, bir "hareket noktası" olarak kullanır. Ürünler depoda uzun süre beklemez; bunun yerine, siparişlere göre hızla ayrıstırılır ve mağazalara gönderilir (Chu, 2005). Bu yaklaşım, envanter tutma maliyetlerini en aza indirir ve hızlı moda iş modelinin gerektirdiği çevikliği destekler.

## **5.3 Ara Depo (Hub-and-Spoke) ve Bölgesel Dağıtım Modeli**

Bu model, merkezi bir veya birkaç ana "hub" (merkez) ile bu merkezlere bağlı, pazarlara daha yakın konumlandırılmış daha küçük bölgesel dağıtım merkezleri veya "spoke"lardan (uç) oluşan hiyerarşik bir ağ yapısıdır.

### **5.3.1 Konsolidasyon ve Ölçek Ekonomileri**

Hub-and-spoke modelinin temel mantığı, konsolidasyona dayanır. Farklı bölgelerden gelen küçük hacimli gönderiler, en yakın "hub"da birleştirilir. Bu birleştirilmiş büyük hacimli sevkiyatlar, hub'lar arasında daha verimli ve birim başına daha düşük maliyetli taşıma modlarıyla taşınır. Hedef hub'a ulaşan sevkiyatlar burada tekrar ayrıstırılır ve daha küçük araçlarla nihai varış noktalarına dağıtilır.

### **5.3.2 Stratejik Faydalar ve Riskler**

Modelin stratejik faydaları arasında daha geniş bir coğrafi alana daha hızlı bölgesel teslimat yapabilme ve taşıma maliyetlerini düşürme bulunur. Ancak, hub'larda yaşanabilecek potansiyel darboğazlar, ağır yönetim karmaşıklığının artması ve birden fazla noktada envanter tutulması gerekliliği gibi riskleri de barındırır.

### 5.3.3 Tasarım ve Optimizasyon Kriterleri

Bir hub-and-spoke ağının tasarımını, dikkatli bir optimizasyon gerektirir. Hub düğümlerinin seçimi, şehrin ekonomik gelişim seviyesi, lojistik talebi, ulaşım altyapısı ve hizmet verdiği hinterlandın genişliği gibi faktörlere bağlıdır (Sun vd., 2023). Lojistik ağ tasarımları, genellikle toplam ağ maliyetlerini minimize etmeyi amaçlayan karmaşık tamsayılı programlama gibi matematiksel optimizasyon modelleri kullanılarak çözülür (Yaman vd., 2007).

### 5.4 Karşılaştırmalı Analiz: Merkezi Dağıtım vs. Hub-and-Spoke

İki model arasındaki tercih, perakendecinin ürün özelliklerine, pazar yapısına ve stratejik önceliklerine bağlıdır

Tablo 1. Merkezi dağıtım modeli ve Hub-and-Spoke modeli karşılaştırması

Kriter	Merkezi Dağıtım Modeli	Hub-and-Spoke Modeli
Maliyet Yapısı	Düşük sabit tesis maliyeti, potansiyel olarak yüksek değişken nakliye maliyetleri (uzun mesafe LTL).	Yüksek sabit hub altyapı maliyeti, konsolidasyon sayesinde daha düşük değişken nakliye maliyetleri.
Envanter Yönetimi	Tek bir noktada merkezileştirilmiş, daha basit ve daha düşük güvenlik stoku seviyeleri.	Hub ve spoke'larda dağıtılmış, daha karmaşık envanter yönetimi.
Nakliye Verimliliği	Direkt sevkiyatlar nedeniyle daha az ölçek ekonomisi, potansiyel olarak daha uzun teslimat süreleri.	Hub'lar arası taşımalarda yüksek konsolidasyon ve ölçek ekonomileri ile artan verimlilik.
Esneklik ve Ölçeklenebilirlik	Talep dalgalarlarına uyum daha yavaş olabilir; coğrafi genişleme yeni bir merkezi depo gerektirebilir.	Yeni spoke'lar eklenerek daha kolay ölçeklenebilir; bölgesel talep değişikliklerine daha hızlı uyum sağlar.
Hizmet Kalitesi	Uzak bölgeler için teslimat hızı daha düşük olabilir.	Sık ve düzenli teslimatlar sayesinde daha yüksek teslimat hızı ve güvenilirlik.

Seçilen lojistik ağ yapısı ne olursa olsun—ister merkezi ister hub-and-spoke olsun—ağ içindeki farklı mağazalarda talep ve arz arasında dengesizlikler oluşması kaçınılmazdır. Bu durum, ağ içinde envanteri dengelemek için daha granüler ve dinamik bir stratejiyi, yani mağazalararası transferleri gerektirir.

### **6.1 Mağazalar Arası Transfer (Lateral Transshipment)**

Mağazalararası transfer (lateral transshipment), bir perakende ağında, bir mağazada stok fazlası varken diğer bir mağazada aynı ürün için yok satma durumu yaşanmasını önlemek amacıyla envanterin yatay olarak yeniden dengelenmesi stratejisidir. Bu uygulama, yalnızca kaybedilecek satışları kurtararak geliri maksimize etmekle kalmaz, aynı zamanda toplam envanter verimliliğini artırarak maliyetleri düşürür. Dolayısıyla, mağazalararası transfer, perakendecilerin tedarik zinciri esnekliğini ve pazar talebine yanıt verme yeteneğini önemli ölçüde artıran güçlü bir stratejik araçtır.

### **6.2 Lateral Transshipment'in Stratejik Önemi**

Mağazalararası transfer veya yanal sevkıyat (lateral transshipment), aynı tedarik zinciri kademesinde bulunan perakende noktaları (örneğin, mağazalar) arasında envanterin yeniden dağıtılması veya paylaşılması olarak tanımlanır (Grahovac ve Chakravarty, 2001). Lateral transshipment stratejisinin temel faydası, envanteri merkezi bir depodan veya harici bir tedarikçiden ikmal beklemeden, ağ içinde proaktif olarak yeniden konumlandırılmasına ve ürünlerin, talebin düşük olduğu bölgelerden yüksek olduğu bölgelere kaydırılması, müşteri teslimat sürelerini kısaltır ve genel müşteri hizmet seviyesini iyileştirir (Garcia vd., 2023). Bu strateji, özellikle talep tahminlerinin doğası gereği belirsizlik içeren durumlarda, tahmin hatalarının olumsuz etkilerini azaltmak için bir sigorta mekanizması görevi görür.

### **6.3 Transshipment Yaklaşımları ve Politikaları**

Literatürde mağazalararası transfer kararlarını yönetmek için farklı zamanlama ve kapsama sahip politikalar geliştirilmiştir.

#### **6.3.1 Reaktif (Acil) Transshipment**

Reaktif transshipment, en basit yaklaşımındır. Bu politikada, bir mağazada müşteri talebi karşılanamadığında, yani bir yok satma durumu fiilen oluştuğunda, acil bir çözüm olarak yakındaki bir mağazadan ürün transferi talep edilir (Grahovac & Chakravarty,

2001). Bu yaklaşım, anlık problemleri çözmeye odaklanır ve genellikle plansızdır.

### 6.3.2 Proaktif (Önleyici) Transshipment

Proaktif transshipment ise, geleceğe yönelik talep tahminlerine dayanarak potansiyel stok dengesizliklerini önceden tespit etmeyi ve bu dengesizlikleri önlemek amacıyla, henüz bir yok satma durumu oluşmadan önce mağazalar arasında envanteri planlı bir şekilde yeniden dengelemeyi hedefler. Bu yaklaşım, daha stratejik ve optimize bir bakiş açısı gerektirir.

Tablo 2. Transfer politikaları karşılaştırması

Politika Türü	Tanım	Projedeki Uygulama
<b>Reaktif Transfer</b>	Yok satma (stock-out) gerçekleştikten sonra yapılan acil transfer.	Sistem, anlık stok verisini izleyerek kritik seviyenin altına düşen mağazaları uyarır.
<b>Proaktif Transfer</b>	Tahminlere dayanarak, yok satma gerçekleşmeden önce yapılan planlı transfer.	<b>Projenin Ana Odak Noktası:</b> Tahminlenen talebe göre stoklar önceden dengelenir.

### 6.3.3 Tam ve Kısmi Havuzlama Politikaları

Transshipment politikaları, agdaki mağazaların ne ölçüde iş birliği yaptığına göre de sınıflandırılabilir. Dada (1984) tarafından incelenen tam havuzlama (complete pooling) politikası, agdaki tüm mağazaların stoklarının tek bir sanal havuz olarak kabul edildiği teorik bir varsayıma dayanır. Buna karşılık, Lee (1987) ve diğer araştırmacılar tarafından ele alınan kısmi havuzlama (partial pooling) politikası, mağazaların stoklarını yalnızca önceden belirlenmiş, genellikle coğrafi olarak yakın olan belirli mağazalarla paylaştığı daha gerçekçi bir senaryoyu modeller (Grahovac & Chakravarty, 2001; Kranenburg & van Houtum, 2009).

## 6.4 Modelleme, Optimizasyon ve Teknoloji Kullanımı

Lateral transshipment kararlarının karmaşıklığı ve "Hangi üründen?", "Hangi

mağazadan hangisine?", "Ne zaman?" ve "Ne kadar?" gibi karmaşık sorulara yanıt araması bu sürecin analitik ve teknolojik araçlarla desteklenmesini gerektirir.

#### **6.4.1 Analistik ve Optimizasyon Modelleri**

Literatürde, mağazalar arası transfer problemlerini modellemek için yarı-Markov karar süreçleri (SMDP), karmaşık tamsayılı doğrusal olmayan programlama (MINLP) ve kısmi diferansiyel denklemler gibi çeşitli matematiksel optimizasyon teknikleri kullanılmıştır (Patriarca vd., 2016; Gholamian & Nasri, 2019). Bu yaklaşım, problemin stokastik ve dinamik doğasını modellemeyi amaçlar. Model, bir yandan transferin getireceği ek lojistik maliyetlerini, diğer yandan ise bu transfer sayesinde elde edilecek potansiyel satış kazancını ve önlenecek envanter tutma maliyetlerini hesaba katarak, toplam sistem maliyetini minimize eden veya toplam karı maksimize eden en uygun transfer planını oluşturur (Ahmadi ve ark., 2019).

#### **6.4.2 Yapay Zeka ve Veri Analitiği Entegrasyonu**

Yapay zeka (AI) ve veri analitiği, mağazalar arası transfer kararlarının etkinliğini önemli ölçüde artırma potansiyeline sahiptir. Gelişmiş makine öğrenmesi tabanlı talep tahmin araçları, proaktif transfer kararları için daha sağlam bir zemin oluşturur. Ayrıca, yapay zeka tabanlı optimizasyon algoritmaları, hangi mağazadan hangi mağazaya, ne zaman ve ne kadar ürün transfer edileceği gibi karmaşık optimizasyon problemlerini daha esnek ve verimli bir şekilde çözebilir (Garcia vd., 2023). Geniş bir perakende ağında lateral transshipment'i gerçek zamanlı olarak optimize etmenin operasyonel karmaşıklığı, gelişmiş AI modellerinin kullanılmasını zorunlu kılmaktadır. Ancak, bu modellerin gücü, kritik bir yönetimsel zorluğu da beraberinde getirir: "kara kutu" doğaları, tedarik zinciri yöneticilerinin, özellikle maliyetli envanter hareketleri içeren önerilere güvenmesini ve bu önerilere göre hareket etmesini zorlaştırır. Bu güven eksikliği, algoritmik güç ile pratik benimseme arasındaki boşluğu doldurmak için Açıklanabilir Yapay Zeka (XAI) tekniklerine yönelik doğrudan ve zorlayıcı bir ihtiyaç yaratmaktadır.

### **7.1 Explainable AI ve Karar Destek Sistemleri**

Yapay zeka modelleri, karar destek sistemlerinde giderek daha merkezi bir rol oynamaktadır. Ancak bu modellerin tahmin doğruluğundaki artış, genellikle model karmaşıklığının artması ve şeffaflığın azalmasıyla birlikte gelir. Bu "kara kutu" doğası, kullanıcıların sistemin önerilerine neden güvenmeleri gerektiği sorusunu gündeme getirir.

Açıklanabilir Yapay Zeka (Explainable AI - XAI), bu soruna yanıt olarak ortaya çıkmış ve yalnızca algoritmik şeffaflık sağlamakla kalmayıp, aynı zamanda insan-makine iş birliğini, karşılıklı güveni ve nihai karar kalitesini artırmada kritik bir rol üstlenmiştir.

## 7.2 Açıklanabilir Yapay Zeka Kavramı

Açıklanabilir Yapay Zeka (XAI), karmaşık makine öğrenmesi modellerinin ("kara kutular") ürettiği tahmin ve kararları insanlar için anlaşılır ve yorumlanabilir hale getirmeyi amaçlayan bir dizi teknik ve yöntemler bütünüdür (Dwivedi vd., 2023; Arrieta vd., 2020). LIME (Local Interpretable Model-Agnostic Explanations) ve SHAP (SHapley Additive exPlanations) gibi popüler model-sonrası (post-hoc) yöntemler, herhangi bir modelin belirli bir tekil tahmini için hangi özelliklerin ne yönde ve ne kadar etkili olduğunu göstererek yerel açıklamalar sunar (Damali vd., 2024).

## 7.3 Karar Destek Sistemlerinde Şeffaflık ve Güven

Karar destek sistemlerinde şeffaflık, kullanıcıların sistemin önerilerini eleştirel bir şekilde değerlendirdip benimsemeleri için temel bir gereklilikdir. Janssen ve arkadaşlarının (2020) yaptığı bir çalışma, daha şeffaf algoritmaların, karar vericilerin algoritmik hataları tespit etme olasılığını artırdığını ve bunun da nihai karar kalitesini doğrudan olumlu etkilediğini göstermiştir. Açıklamalar aynı zamanda "güven kalibrasyonu" (trust calibration) adı verilen önemli bir işlevi yerine getirir. Kullanıcıların, sistemin yetenekleri hakkında ne aşırı iyimser ne de aşırı kötümser bir güven seviyesi geliştirmesini önlemeye yardımcı olur, böylece kullanıcının sistemi ne zaman dinleyeceğini ve ne zaman kendi muhakemesine başvuracağını bilmesini sağlar (Lim vd., 2019).

## 7.4 BI Panelleri, Bilgi Ekranları ve Yönetici Arayüzleri

XAI tekniklerinden elde edilen açıklamaların değeri, ancak son kullanıcıya etkili bir şekilde sunulduğunda ortaya çıkar. Bu nedenle, açıklamaların yöneticilerin zaten aşina olduğu İş Zekası (BI) panelleri ve yönetici bilgi ekranları (dashboards) gibi karar destek arayüzlerine entegre edilmesi kritik öneme sahiptir. Meske ve Bunde'nin (2022) XAI tabanlı bir DSS için geliştirdiği kullanıcı arayüzü tasarım ilkeleri, bu entegrasyonun kullanıcının bilişsel yükünü azaltmayı, algılanan bilgilendiriciliği artırmayı ve sisteme duyulan güvenilirliği pekiştirmeyi hedeflemesi gerektiğini vurgulamaktadır. Bu arayüzler, kullanıcıya sadece modelin nihai tahminini (örneğin, "Bu ürününden haftaya 100 adet satılacak") sunmakla kalmaz, aynı zamanda bu tahminin arkasındaki temel nedenleri de

anlaşılır bir şekilde görselleştirir (Pal, 2024). Örneğin, "Bu tahminin en önemli nedenleri; yaklaşan bayram tatili, rakip firmanın promosyonunun sona ermesi ve olumlu hava durumu tahminidir" gibi açıklamalar, yöneticinin kararı bağlam içinde değerlendirmesine olanak tanır (Akter ve Kudapa, 2024). Bu tür arayüzler, yönetici karar kalitesini doğrudan etkileme potansiyeline sahiptir.

### **7.5 Explainable AI'nın Yönetici Karar Kalitesine Etkisi**

XAI'nın temel amacı, yöneticileri pasif bir alıcı konumundan çıkarıp, AI ile iş birliği yapan aktif bir karar verici konumuna getirmektir. Açıklamalar sayesinde bir yönetici, bir modelin çıktısını sadece kabul veya reddetmekle kalmaz, aynı zamanda bu çıktıyı kendi uzmanlık bilgisiyle birleştirerek daha nitelikli kararlar alabilir. Janssen ve arkadaşlarının (2020) çalışması, açıklamaların özellikle deneyimli karar vericiler tarafından kullanıldığında karar doğruluğunu önemli ölçüde artırdığını, bununla birlikte deneyimsiz kullanıcılar için bile karar verme sürecinde daha tutarlı olmalarına yardımcı olduğunu ortaya koymuştur. Bu bulgular, XAI'nın sadece bir "şeffaflık aracı" değil, aynı zamanda etkili bir "karar kalitesi artırma aracı" olduğunu göstermektedir. DSS temelleri, stok yönetimi, gelişmiş tahminleme ve açıklanabilirlik gibi incelenen tüm bu literatür alanlarının bütüncül bir sentezi, mevcut araştırma boşluklarını ve fırsatları ortaya koyarak bu çalışmanın konumunu belirlemektedir.

## **8.1 Literatürün Sentezi ve Çalışmanın Konumlandırılması**

Önceki bölümlerde detaylı olarak incelenen Karar Destek Sistemleri, perakende stok yönetimi, talep tahminleme, lojistik ağ yapıları, mağazalar arası transfer ve Açıklanabilir Yapay Zeka (XAI) literatürü, modern perakende tedarik zincirlerinin karmaşıklığını yönetmek için birbirini tamamlayan, ancak çoğu zaman birbirinden kopuk olarak ele alınan alanları temsil etmektedir. Her bir alan kendi içinde önemli ilerlemeler kaydetmiş olsa da, bu alanlar arasındaki kesişim noktalarındaki entegrasyon eksiklikleri, bütüncül ve pratik karar destek çözümlerinin geliştirilmesi önünde önemli bir engel teşkil etmektedir. Bu çalışma, tam da bu kesişim noktalarında konumlanarak literatürdeki mevcut boşlukları doldurmayı hedeflemektedir.

## **8.2 Literatürdeki Boşluklar**

İncelenen literatürün sistematik bir değerlendirmesi sonucunda aşağıdaki temel araştırma boşlukları tespit edilmiştir. İncelenen literatür, talep tahminleme, envanter

optimizasyonu ve mağazalar arası transfer gibi problemlerin genellikle birbirinden izole edilmiş akademik çalışmalar olarak ele alındığını göstermektedir. Bu problemlerin tek bir bütüncül karar destek çerçevesi içinde entegre edildiği ve aralarındaki dinamik etkileşimlerin modellendiği çalışmalar sınırlıdır. Özellikle, yeni ürünler için soğuk başlangıç problemini ele alan tahmin modellerinin çıktılarının, proaktif mağazalar arası transfer gibi envanter deneleme stratejilerini doğrudan beslediği entegre optimizasyon yaklaşımı nadirdir. Bununla birlikte en önemli eksikliklerden biri, bu karmaşık optimizasyon modellerinin ürettiği önerilerin, son kullanıcı olan planlama yöneticilerine şeffaf, anlaşılır ve güvenilir bir şekilde sunulmasını sağlayan, Açıklanabilir Yapay Zeka (XAI) entegre Karar Destek Sistemi tasarımlarının literatürde sınırlı sayıda olmasıdır.

**Entegre Optimizasyon Eksikliği:** Talep tahminlemesi ve envanter optimizasyonu, literatürde genellikle birbirinden ayrı ve sıralı problemler olarak ele alınmaktadır. Bu yaklaşım, bu iki fonksiyon arasındaki karşılıklı geri besleme döngüsünü ve dinamik etkileşimi göz ardı etmektedir. Örneğin, envanter kararları doğrudan ürün bulunurluğunu etkileyerek gelecekteki talebi şekillendirebilir (Kumar vd., 2025).

**"Kara Kutu" Modellerinin Benimsenme Engeli:** Talep tahmininde ve optimizasyonda kullanılan gelişmiş makine öğrenmesi modelleri, yüksek doğruluk oranları sunmalarına rağmen, "kara kutu" doğaları gereği karar süreçleri şeffaf değildir. Bu şeffaflık eksikliği, yöneticilerin bu sistemlere olan güvenini azaltmakta ve modellerin pratik olarak DSS içinde benimsenmesinin önünde önemli bir engel teşkil etmektedir.

**Kullanıcı Odaklı Açıklanabilirlik Arayüzlerinin Sınırlılığı:** XAI üzerine yapılan araştırmaların büyük bir kısmı, algoritmik olarak açıklamaların nasıl üretileceğini odaklanmaktadır. Ancak bu açıklamaların, teknik bilgisi olmayan son kullanıcıya (örneğin bir mağaza müdürü) BI panelleri ve karar arayüzleri gibi pratik araçlar üzerinden nasıl sunulması gereği ve bu sunumun karar kalitesine etkisi üzerine yapılan çalışmalar oldukça sınırlıdır (Meske & Bunde, 203

### 8.3 Bu Çalışmanın Katkısı ve Farklılaşan Yönleri

Bu tez, yukarıda tespit edilen literatür boşluklarını doldurmayı hedefleyerek literatüre hem teorik hem de pratik düzeyde özgün katkılar sunmayı amaçlamaktadır. Çalışmanın temel katkısı ve mevcut yaklaşılardan farklılaşan yönleri şu şekilde özetlenebilir: Büyücül ve entegre bir Karar Destek Sistemi çerçevesi sunarak literatürdeki mevcut çalışmalardan farklılaşmasıdır. Çalışmanın en özgün yönü ise, geliştirilen analitik modellerin sonuçlarını karar vericiler için yorumlanabilir kıyan Açıklanabilir Yapay Zeka

(XAI) prensiplerini sistem tasarımının merkezine yerleştirmesidir. Bu bağlamda, çalışmanın benimsediği XAI perspektifi aşağıdaki gibi özetlenebilir: "Explainable AI, bu çalışmada yalnızca model çıktılarının açıklanması için değil, karar vericinin güvenini artıran bir karar destek arayüzü bileşeni olarak ele alınmaktadır. Bu çalışma, birbirinden kopuk ele alınan talep tahminlemesi, stok optimizasyonu ve mağazalararası transfer kararlarını, tek ve bütüncül bir karar destek sistemi çerçevesi içinde entegre etmeyi önermektedir. Geliştirilecek sistem, yalnızca tahmin ve optimizasyonun doğruluğuna değil, aynı zamanda bu kararların arkasındaki mantığın şeffaflığına ve yorumlanabilirliğine de eşit derecede odaklanacaktır. Çalışmanın temel farklılığı, Açıklanabilir Yapay Zeka'yı ele alış biçimindedir. Explainable AI, bu çalışmada yalnızca model çıktılarının açıklanması için değil, karar vericinin güvenini artıran bir karar destek arayüzü bileşeni olarak ele alınmaktadır. Bu yaklaşım, çalışmayı "sadece model geliştiren bir öğrenci" perspektifinden, "kullanıcı odaklı ve güvenilir bir sistem tasarlayan bir mühendis" perspektifine taşımaktadır. Sonuç olarak bu tez, karmaşık teorik modellemeyi, insan-merkezli sistem tasarımları prensipleriyle birleştirerek literatüre pratik ve yenilikçi bir katkı sunmayı amaçlamaktadır.

## **2. METODOLOJİ**

Geliştirilen Perakende Karar Destek Sistemi'nin (KDS) teknik ve teorik altyapısını, projenin sınırlarını (kısıtlarını) ve yaklaşımları detaylandırmaktadır. Bölümün amacı, alınan kararları akademik ve teknik gerekçelerini ortaya koymaktır.

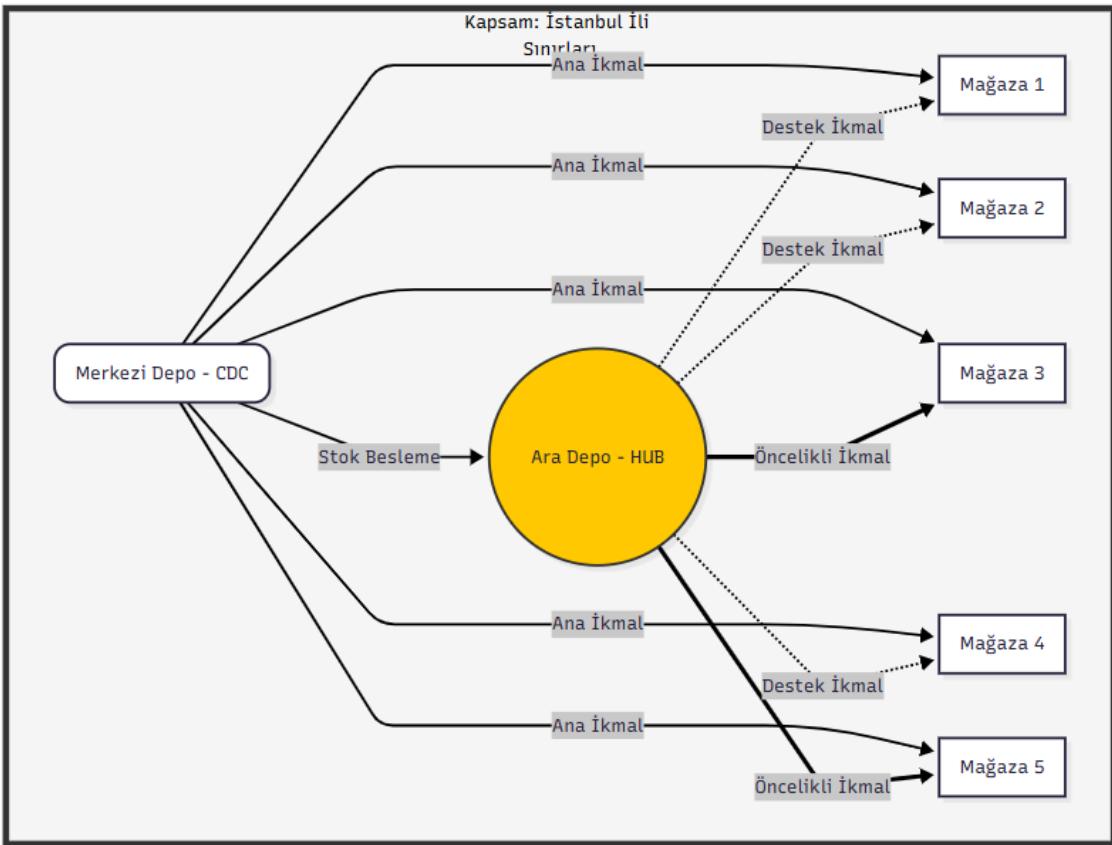
### **3.1 Proje Kısıtları ve Zorluklar**

**Veri Kısıtları:** Soğuk Başlangıç (Cold Start) Problemi: Sistem, geçmiş satış verilerine dayalı tahminleme yaptığı için, yeni açılan bir mağaza veya portföye yeni eklenen bir ürün söz konusu olduğunda "Soğuk Başlangıç" (Cold Start) problemi ortaya çıkmaktadır.

Yeni ürün dağıtıımı, yeni mağaza açılması problemi, Geçmiş verisi olmayan (history-blind) bir lokasyon için talep tahmini yapılamamaktadır. Literatürde bu problem genellikle Similarity-based Forecasting (Benzerlik Bazlı Tahmin) veya Reference Class Forecasting yöntemleri ile aşılmaktadır. Yeni bir mağaza açıldığında, o mağazanın demografik özelliklerine (müşteri profili: öğrenci, lüks vb.) en çok benzeyen mevcut mağazaların satış verileri referans alınarak (Clustering/Kümeleme) ilk ürün sevkiyatı (Initial Allocation) planlanmaktadır. k-Nearest Neighbors (k-NN) algoritmalarının perakende talep tahmininde kullanımı üzerine yapılan çalışmalar (F.L. Chen, "Sales forecasting by combining clustering and machine learning"), benzer mağazaların davranışlarının yeni mağazalara uyarlanabileceğini göstermektedir.

#### **3.1.1 Kapsam ve Topoloji Kısıtları**

Tek Bölge Kısıtı, simülasyon sadece İstanbul ili sınırları içerisindeki 5 mağaza ve 1 ara depo ile sınırlanmıştır. Lojistik kısıtlar araç kapasiteleri ve trafik yoğunluğu (Vehicle Routing Problem) bu fazda kapsam dışı bırakılmıştır.



Şekil 1. Kapsam ve topoloji kısıtları şeması

### 3.1.2 Teknik Kısıtlar ve Mimari Tercih Monolitik Yapı

Proje, Modüler Monolitik (Modular Monolith) mimari üzerinde kurgulanmıştır.

Tüm iş modülleri (stok, satış, transfer) tek bir çalışma zamanı (runtime) ve veritabanı bağlantısı üzerinde çalışmaktadır. Backend FastAPI framework'ü ile, frontend ise React kütüphanesi ile geliştirilmiştir. Martin Fowler ve diğer yazılım mimarisini otoriteleri, dağıtık sistemlerin (Distributed Systems / Microservices) getirdiği ağ gecikmesi (network latency) ve veri tutarlılığı (data consistency – CAP Theorem) karmaşıklığının, henüz olgunlaşmamış veya küçük ve orta ölçekli projeler için gereksiz bir maliyet (overhead) yarattığını belirtmektedir. Monolitik yapı, ACID (Atomicity, Consistency, Isolation, Durability) prensiplerinin uygulanmasını kolaylaştırarak, özellikle stok transferleri gibi kritik işlemlerde veri tutarlığını garanti altına almaktadır.

Tablo 3. Projede kullanılan teknik mimari ve araçlar

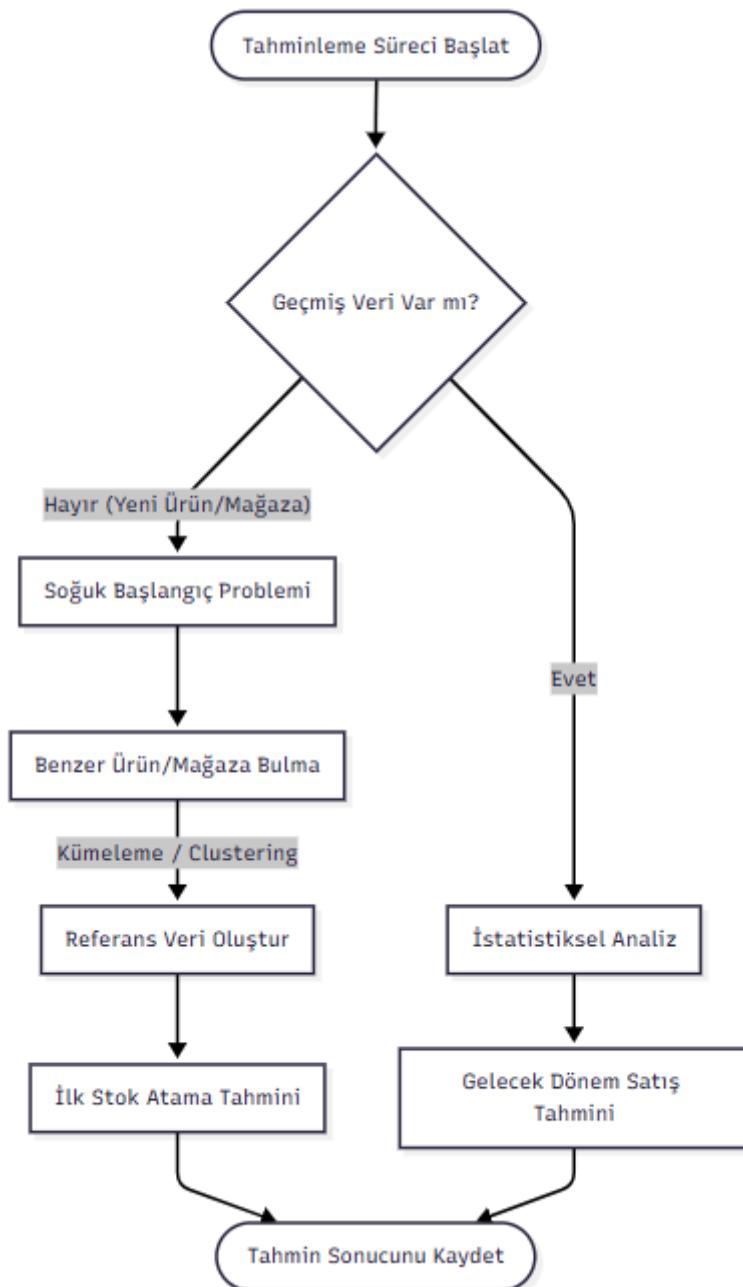
Bileşen	Kullanılan Teknoloji / Yöntem	Seçim Gerekçesi
<b>Mimari Yapı</b>	Modüler Monolitik (Modular Monolith)	Veri tutarlığını (ACID) sağlamak ve ağ gecikmesini (latency) minimize etmek.
<b>Backend (Sunucu)</b>	Python / FastAPI	Yüksek performanslı asenkron yapı ve veri bilimi kütüphaneleriyle (Pandas, Numpy) tam uyum.
<b>Frontend (Arayüz)</b>	React.js	Kullanıcı dostu, dinamik ve reaktif bir yönetici paneli (Dashboard) oluşturmak.
<b>Veritabanı</b>	SQLite (Geliştirme) / SQL İlişkisel	İlişkisel veri yapısı (Satış, Stok, Mağaza) için uygunluk ve kurulum kolaylığı.
<b>Veri Kaynağı</b>	Sentetik Veri (Faker Library)	Ticari veri gizliliği nedeniyle gerçekçi senaryoları simüle eden yapay veri üretimi.

### 3.1.3 Veritabanı Yönetimi: İlişkisel Veritabanı

Büyük ölçekli perakende uygulamalarında (ERP sistemleri), veri bütünlüğü, karmaşık sorgulama yetenekleri ve transaksiyonel güvenilirlik (ACID) nedeniyle ilişkisel veritabanları tercih edilmektedir. Yöntem olarak SQLite (Geliştirme Ortamı) kullanıldı. Alternatif ve Kurumsal çözüm olarak Microsoft SQL Server (MSSQL), PostgreSQL yöntemleri kullanılabilir. Satış ve envanter verileri ilişkisel bir yapıdadır.

### 3.1.4 Talep Tahminleme

Geçmiş satış verileri analiz edilerek gelecek dönem talepleri öngörmeye çalışılmaktadır. Mevcut durumda Hareketli Ortalama Gibi temel istatistiksel yöntemler temel alınmıştır. Geliştirme planı olarak mevsimsellik (*seasonality*) ve trend etkilerini daha iyi yakalayabilen SARIMA veya Prophet gibi yöntemlerin sisteme entegre edilmesi planlanmaktadır.



Şekil 2. Talep tahminleme ve soğuk başlangıç şeması

## **Derin Öğrenme Modellerinin (LSTM vb.) Tercih Edilmemesinin Gerekçeleri**

Veri hacmi ve çeşitliliği, LSTM gibi derin öğrenme modellerinin stabil ve

genellenebilir şekilde eğitilmesi için yeterli değildir. Sentetik veri ile eğitilen karmaşık modeller, gerçek dünya verisiyle karşılaşlığında aşırı uyum (overfitting) ve model çökmesi (model drift) riski taşımaktadır. Karar destek sistemlerinde açıklanabilirlik (explainability), tahmin doğruluğu kadar kritik olup, istatistiksel yöntemler yöneticilere daha şeffaf ve izlenebilir karar gerekçeleri sunmaktadır.

### **Kapsam Sınırlaması:**

Bu çalışma sistemleri birleştirmek, çalışan veya yöneticinin kararına destek vermek amaçlı yapıldığından talep tahminleme veya gibi konular, karar destek sürecini besleyecek temel girdileri üretmek amacıyla arayüzde gösterilmesi hedeflenen işlemler temel istatistiksel yöntemler ile sınırlandırılmıştır.

Tablo 4. Karar destek sistemi modül ve algoritmalar

Modül Adı	Çözülen Problem	Kullanılan Yöntem / Algoritma	Açıklama
Talep Tahminleme	Gelecek dönem satış belirsizliği	<b>Hareketli Ortalama (Moving Average)</b>	Geçmiş satış verilerinin ortalaması alınarak trendler belirlenir.
Stok Optimizasyonu	Mağazalar arası stok dengesizliği	<b>Açgözlü Sezgisel (Greedy Heuristic)</b>	"En çok ihtiyacı olanı, en çok fazla olandan besle" (Robin Hood) ile çalışır.
Lojistik Ağ	Dağıtım maliyeti ve süre optimizasyonu	<b>Hub-and-Spoke (Melez Yapı)</b>	Merkezi depo ile mağazalar arasına "Ara Depo" eklenerken tepki süresi kısaltılır.
Açıklanabilirlik	"Kara Kutu" problemi ve kullanıcı güveni	<b>XAI (Açıklanabilir Yapay Zeka)</b>	Sistemin bu transferi önermesi kullanıcıya gerekçeli (Rule-based explanation) olarak sunulur.

### **3.1.5 Stok Optimizasyonu**

NP-Hard, Stok transfer ve rotalama problemleri, bilgisayar bilimlerinde NP-Hard sınıfına giren problemlerdir. Mağaza sayısı arttıkça olası transfer kombinasyonlarının sayısı üstel olarak artmaktadır, bu da kesin çözümün pratik sürede bulunmasını zorlaştırmaktadır. Çözüm Yaklaşımı olarak Greedy Heuristic (Robin Hood Mantığı) benimsenmiştir. NP-Hard problemlerin kesin çözümü yüksek hesaplama maliyeti gerektirdiği için, bu projede açgözlü sezgisel algoritma yaklaşımı benimsenmiştir.

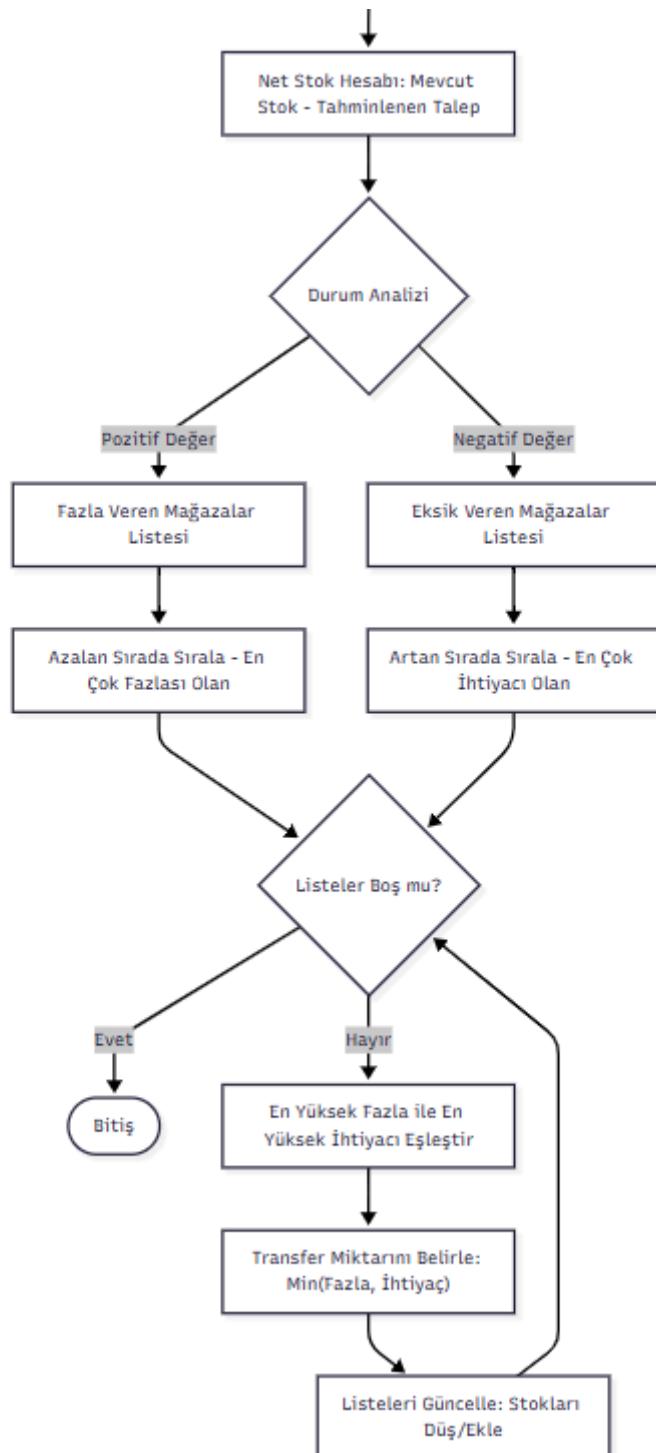
#### **Çalışma Prensibi:**

Stok fazlası olan mağazalar ile stok eksiği olan mağazalar belirlenir.

En yüksek ihtiyaç ile en yüksek fazla eşleştirilir.

Transfer gerçekleştirilir ve sistem güncellenir.

Bu yaklaşım, literatürde *Lateral Transshipment* olarak adlandırılmasında ve merkezi depoya olan bağımlılığı azaltarak tepki süresini kısaltmaktadır (Paterson et al., *European Journal of Operational Research*).



Şekil 3. Heuristic (sezgisel) algoritma şeması (Robin Hood Mantığı)

### Gelecek İçin Geliştirme Önerileri

Hibrit tahminleme yöntemleri ile istatistiksel yöntemler ve Makine Öğrenmesi birleştirilerek hata payları düşürülebilir.

Genetik algoritmalar ile NP-Hard olan problemin çözümü için, evrimsel hesaplamalı algoritmalar kullanılarak daha optimum sonuçlara ulaşılabilir. Bulut entegrasyonu ile veritabanı olarak Azure SQL veya AWS RDS kullanılarak ölçeklenebilirlik artırılabilir.

### 3. SONUÇ

Bu çalışma kapsamında, perakende sektöründe sıkılıkla karşılaşılan stok dengesizliği, talep belirsizliği ve geç karar alma problemlerine yönelik, bütünlük ve açıklanabilir bir Karar Destek Sistemi (KDS) prototipi geliştirilmiştir. Yöneticileri veri odaklı, hızlı ve güvenilir karar mekanizmalarına yönlendirmektedir. Geliştirilen sistem, bu ihtiyaca doğrudan yanıt vermesi istenerek, perakende operasyonlarında karar alma süreçlerini destekleyen fonksiyonel bir dijital altyapı sunmuştur.

Çalışmada tasarlanan lojistik ağ yapısı; merkezi depo, ara depo (hub) ve perakende mağazalarından oluşan çok kademeli bir yapı üzerinden modellenmiştir. Bu yapı, gerçek hayat operasyonlarını yansıtacak şekilde İstanbul ili özelinde kurgulanmış ve sistem davranışları sentetik fakat gerçekçi verilerle test edilmiştir. Sentetik veri üretimi sürecinde mevsimsellik, trend ve talep dalgalarını gibi perakende sektörüne özgü dinamiklerin dikkate alınması, geliştirilen karar destek mekanizmasının gerçek dünyaya uyarlanabilirliğini artırmıştır. Bu yaklaşım, veri gizliliği ve ticari sırları altında dahi akademik ve teknik hipotezlerin test edilebileceğini göstermesi açısından önemli bir katkı sunmaktadır.

Stok optimizasyonu modülünde benimsenen Lateral Transshipment (mağazalar arası transfer) stratejisi, sistemin operasyonel değer üreten en kritik bileşenlerinden biri olmuştur. NP-Hard karmaşıklığa sahip transfer problemi, Ağözlü Sezgisel (Greedy Heuristic) yaklaşım ile modellenmiş ve “Robin Hood” mantığıyla stok fazlası olan mağazalardan stok açığı yaşayan mağazalara hızlı transfer kararları üretilmiştir. Elde edilen sonuçlar, merkezi depoya bağımlı sevkiyatlara kıyasla mağazalar arası transferlerin tepki süresini önemli ölçüde kısalttığını, yok satma riskini azalttığını ve sistem genelinde stok kullanım verimliliğini artırdığını göstermiştir. Bu bulgu, özellikle yoğun rekabet ortamında faaliyet gösteren perakendeciler için operasyonel bir avantaj oluşturmaktadır.

Talep tahminleme modülünde, veri setinin yapısı ve soğuk başlangıç (cold start) problemi göz önünde bulundurularak istatistiksel yöntemler tercih edilmiştir. Geçmiş satış verisi bulunmayan yeni ürünler ve mağazalar için teorik olarak entegre edilen benzerlik tabanlı tahmin yaklaşımı, sistemin yalnızca mevcut operasyonları değil, yeni ürün lansmanlarını da destekleyebilecek bir karar altyapısına sahip olmasını sağlamıştır. Bu durum, geliştirilen sistemin statik bir raporlama aracı değil; değişen pazar koşullarına uyum sağlayabilen dinamik bir karar destek mekanizması olduğunu ortaya koymaktadır.

Bu yapı, projenin yalnızca akademik bir simülasyon olarak kalmayıp, KOBİ ölçüğindeki perakendeciler için yüksek maliyetli ERP çözümlerine alternatif olabilecek

ticari bir ürüne dönüşme potansiyelini de ortaya koymaktadır. Sistem tarafından üretilen transfer ve stok dengeleme önerileri, kullanıcıya yalnızca “ne yapılmalı” sorusunun cevabını vermekle kalmamış; aynı zamanda “neden bu karar öneriliyor” sorusuna da açık ve anlaşılır gerekçeler sunmuştur. Bu yaklaşım, yöneticilerin sisteme duyduğu güveni artırmış, karar alma sürecinde insan–makine iş birliğini güçlendirmiştir.

Sonuç olarak bu çalışma; lojistik ağ tasarımlı, istatistiksel talep tahminleme ve sezgisel optimizasyon tekniklerini modern web teknolojileriyle birleştiren, uçtan uca bir perakende karar destek sistemi prototipi ortaya koymuştur. Geliştirilen sistem, stok yönetiminde verimsizlikten kaynaklanan maliyetleri azaltma, yok satma riskini düşürme ve yöneticilere proaktif karar alma kabiliyeti kazandırma potansiyeline sahiptir. Gelecek çalışmalarda, talep tahminleme modülünün LSTM gibi derin öğrenme mimarileriyle hibrit hale getirilmesi, transfer optimizasyonunda Genetik Algoritmalar veya Metasezgisel yöntemlerin kullanılması ve sistemin gerçek zamanlı verilerle test edilmesi hedeflenmektedir. Mevcut haliyle proje, perakende sektöründe dijital dönüşümü destekleyen, sürdürülebilir ve ölçülebilir bir karar destek yaklaşımı olarak literatüre ve sektörrel uygulamalara anlamlı bir katkı sunmayı amaçlamaktadır.

## KAYNAKLAR

- Abdullah, S. (2012). The relation between data warehouse and business intelligence. *arXiv Preprint*, arXiv:1205.0724v1.
- Adeyemi, S. L., ve Salami, O. A. (2010). Inventory management: A tool of optimizing resources in a manufacturing industry (A case study of Coca-Cola Bottling Company, Ilorin Plant). *Journal of Social Sciences*, 23(2), 135–142.
- Agarwal, A., Amjad, M. J., Shah, D., ve Shen, D. (2017). Time series forecasting via matrix estimation. *arXiv Preprint*, arXiv:1710.08473v2.
- Ahmadi, S., Pishvaee, M. S., ve Mohammadi, M. (2019). Designing a sustainable supply chain network with lateral transshipment of products. *International Journal of Supply and Operations Management*, 12(2), 143–162.
- Akter, T., ve Kudapa, S. S. (2024). AI-integrated dashboards for supply chain visibility and real-time decision-making: A systematic review. *International Journal of Scientific and Innovative Research*, 5(2), 175–192.
- Aljazzar, S. M., Gurtu, A., ve Jaber, M. Y. (2018). A new inventory model for a two-echelon supply chain with quantity and freight discounts. *Journal of Modelling in Management*, 13(2), 274–296.
- Alkhailah, T., Feng, D., ve Yuan, Y. (2022). MLReal: Bridging the gap between training on synthetic and application to real data. *Artificial Intelligence in Geosciences*, 3, 101–114.
- Antoniadi, A. M., Du, Y., Guendouz, Y., Wei, L., Mazo, C., Becker, B. A., ve O'Regan, K. (2021). A systematic review of explainable artificial intelligence in clinical decision support systems. *Applied Sciences*, 11(11), 5088.
- Bhatt, U., Xiang, A., Sharma, S., Weller, A., Taly, A., Jia, Y., Ghosh, J., Puri, R., Moura, J. M. F., ve Eckersley, P. (2021). Uncertainty as a form of transparency: Measuring, communicating, and using uncertainty. *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 369–379.
- Grahovac, J., ve Chakravarty, A. K. (2001). Sharing and lateral transshipment of inventory in a supply chain. *Management Science*, 47(4), 579–594.
- Gürbüz, A. S. (2024). Comparative analysis of classical time-series forecasting models: A case study on retail sales data. *International Transactions on Innovative Engineering, Communications and Sciences & Technology*, 1(2), 1–13.
- Ieracitano, C., Mammone, N., Spagnolo, F., Frustaci, F., Perri, S., Corsonello, P., ve Morabito, F. C. (2024). An explainable embedded neural system for on-board ship detection from optical satellite imagery. *Engineering Applications of Artificial Intelligence*, 133, 108517.
- Jacobsen, J. K. (2023). Machine learning and the politics of synthetic data. *Big Data & Society*, 10(2).

- Janssen, M., van der Voort, H., ve Wahyudi, A. (2020). Will algorithms blind people? The effect of explainable AI and decision-makers' experience on AI-supported decision-making. *Social Science Computer Review*, 40(2), 479–498.
- JISEM. (2025). Order management and supply chain optimization functions. *Journal of Information Systems Engineering and Management*, 10(63s), 1191.
- Kaya, O., Gürbüz, Ö., ve Torka, M. (2020). Demand forecasting for new fashion products based on clustering and classification. *Journal of Fashion Marketing and Management*, 24(2), 231–245.
- Kootanaee, A. J., Babu, K. N., ve Kumar, H. (2013). The impact of modern inventory control techniques on supply chain performance. *International Journal of Social, Management, Economics and Business Engineering*, 7(12), 1735–1738.
- Lee, S., Park, J., ve Park, C. H. (2023). A study on hub-and-spoke logistics systems for retail supply chain agility. *International Journal for Multidisciplinary Research (IJFMR)*, 5(3).
- Lu, Y., Chen, L., Zhang, Y., Shen, M., Wang, H., Wang, X., van Rechem, C., Fu, T., ve Wei, W. (2023). Machine learning for synthetic data generation: A review. *arXiv Preprint*, arXiv:2302.04062v10.
- Menon, A., Rask, E., ve Sharma, A. (2007). Distribution network redesign for marketing competitiveness. *Journal of Marketing*, 71(2), 134–150.
- Molodoria, A. (2024). The strategic imperative of AI-driven demand forecasting in retail operations. *International Journal on Science and Technology (IJSAT)*, 8(1), 1–10.
- Ogbo, A. I., ve Onekamma, I. V. (2014). The impact of inventory management on the organizational performance (A study of 7up Bottling Company, 9th Mile Enugu). *International Journal of Management and Information Technology*, 10(1), 1840–1850.
- Pal, R. (2024). Integrating explainable AI (XAI) into decision support systems: A framework for enhancing transparency and trust in managerial decision-making. *AI & Society*.
- Pals, V. K., van der Vlist, P., ve de Koster, R. (2009). Optimal policies for lateral transshipments in a two-location inventory system. *ERIM Report Series*, ERS-2009-027-LIS.
- Pauwels, K., Ambler, T., Clark, B. H., LaPointe, P., Reibstein, D., Skiera, B., Wierenga, B., ve Wiesel, T. (2009). Dashboards as a service: Why, what, how, and what research is needed? *Journal of Service Research*, 12(2), 175–189.
- Power, D. J. (2017). Revisiting Ralph Sprague's framework for developing decision support systems. *Communications of the Association for Information Systems*, 42, 358–379.
- Saleh, F., Kucukelbir, A., ve Blei, D. M. (2022). A deep learning approach for sales forecasting of new fashion products. *Forecasting*, 4(2), 565–579.

- Schmeisser, F., Koch, P., Groll, A., ve Schauberger, G. (2024). Glocal explanations of expected goal models in football. *Lecture Notes in Computer Science*, 14815, 159–173.
- Sevinç, Ü., ve Küçüksille, E. U. (2015). Konfeksiyon endüstrisinde perakende talep tahminlemesi. *Tekstil ve Mühendis*, 22(99), 1–10.
- Shumway, R. H., ve Stoffer, D. S. (2017). *Time series analysis and its applications: With R examples*. Springer.
- Tokatlı, N. (2017). Global sourcing and the shifting centers of gravity: Zara's changing model of the geography of production and consumption. *Journal of Economic Geography*, 17(1), 21–41.
- Van der Walt, J. D., Kruger, K., ve Van Eeden, J. (2022). The integrated retail ordering system (IROS) framework for improved inventory replenishment at a South African retailer. *arXiv Preprint*, arXiv:2207.13923v1.
- Wong, W. K., ve Guo, Z. X. (2010). A hybrid intelligent model for medium-term sales forecasting in fashion retail. *Expert Systems with Applications*, 37(4), 3185–3192.

# ÖZGEÇMİŞ

## Kişisel Bilgiler

Adı Soyadı : İbrahim TÜRKYILMAZ  
İkamet Yeri : İstanbul, Sultangazi  
Doğum Tarihi : 12.02.2004  
Mail Adresi : [ibrahimtrkylmz632@gmail.com](mailto:ibrahimtrkylmz632@gmail.com)  
Telefon : +90 544 572 3312



LinkedIn Profili <https://www.linkedin.com/in/ibrahim-turk-yilmaz-68a188253/>

## Eğitim

Lise Bahattin Yıldız Anadolu Lisesi (Sayısal, Matematik / Fen)  
Lisans İstanbul Rumeli Üniversitesi Endüstri Mühendisliği

## İş Deneyimi

Yıl	Yer	Görev
01.07.2025	LC Waikiki Mağazacılık Hizmetleri	İş Analitiği Stajyeri
01.08.2025	Ticaret A.Ş.	
19.08.2024	CSM METALURJİ MAKİNE SANAYİ	Üretim Stajyeri
20.09.2024	A.Ş.	
01.06.2024	QNB Bank A.Ş.	Gönüllü Stajyer
26.06.2024		